

기계학습과 수학

선형대수

벡터와 행렬


- 벡터

- 샘플을 특징 벡터로 표현

예) Iris 데이터에서 꽃받침의 길이, 꽃받침의 너비, 꽃잎의 길이, 꽃잎의 너비라는 4개의 특징이 각각 5.1, 3.5, 1.4, 0.2인 샘플

$$\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{pmatrix} = \begin{pmatrix} 5.1 \\ 3.5 \\ 1.4 \\ 0.2 \end{pmatrix}$$

예) 사진(image)을 벡터화하여 표현하는 과정



- 여러 개의 특징 벡터를 첨자로 구분 (\mathbf{x}_i)

$$\mathbf{x}_1 = \begin{pmatrix} 5.1 \\ 3.5 \\ 1.4 \\ 0.2 \end{pmatrix}, \mathbf{x}_2 = \begin{pmatrix} 4.9 \\ 3.0 \\ 1.4 \\ 0.2 \end{pmatrix}, \mathbf{x}_3 = \begin{pmatrix} 4.7 \\ 3.2 \\ 1.3 \\ 0.2 \end{pmatrix}, \dots, \mathbf{x}_{150} = \begin{pmatrix} 5.9 \\ 3.0 \\ 5.1 \\ 1.8 \end{pmatrix}$$

- 종류와 크기 표현의 예) $\mathbf{x} \in \mathbb{R}^n$

- 행렬

- 여러 개의 벡터를 담음

요소: $x_{i,j}$, i 번째 행: $x_{i,:}$, j 번째 열: $x_{:,j}$

- 훈련집합을 담은 행렬 : 설계행렬

$$\mathbf{X} = \begin{pmatrix} 5.1 & 3.5 & 1.4 & 0.2 \\ 4.9 & 3.0 & 1.4 & 0.2 \\ 4.7 & 3.2 & 1.3 & 0.2 \\ 4.6 & 3.1 & 1.5 & 0.2 \\ \vdots & \vdots & \vdots & \vdots \\ 6.2 & 3.4 & 5.4 & 2.3 \\ 5.9 & 3.0 & 5.1 & 1.8 \end{pmatrix} = \begin{pmatrix} x_{1,1} & x_{1,2} & x_{1,3} & x_{1,4} \\ x_{2,1} & x_{2,2} & x_{2,3} & x_{2,4} \\ x_{3,1} & x_{3,2} & x_{3,3} & x_{3,4} \\ x_{4,1} & x_{4,2} & x_{4,3} & x_{4,4} \\ \vdots & \vdots & \vdots & \vdots \\ x_{149,1} & x_{149,2} & x_{149,3} & x_{149,4} \\ x_{150,1} & x_{150,2} & x_{150,3} & x_{150,4} \end{pmatrix}$$


행 row

열 column

$$\begin{bmatrix} 4 & -3 & 1 & 3 \\ 2 & 0 & 5 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 5 \\ 8 \end{bmatrix} \text{ and } \begin{bmatrix} 4 & -3 & 1 & 3 \\ 2 & 0 & 5 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 4 \\ -1 \\ 3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

Diagram illustrating matrix multiplication by A from \mathbb{R}^d to \mathbb{R}^2 . The first part shows a vector x being multiplied by A to produce b . The second part shows a vector u being multiplied by A to produce 0 .

대표적 변환 예)



○ 텐서

■ 3차원 이상의 구조를 가진 숫자 배열

- 0차 : 수(Scalar)
- 1차 : 벡터
- 2차 : 행렬
- 고차원 ...

예) 3차원 구조의 RGB 컬러 영상

$$A = \begin{pmatrix} \begin{pmatrix} 3 & 0 & 1 & 2 & 6 & 7 \\ 3 & 1 & 2 & 3 & 5 & 6 \\ 1 & 2 & 2 & 2 & 2 & 3 \\ 3 & 0 & 0 & 1 & 1 & 0 \\ 5 & 4 & 1 & 3 & 3 & 3 \\ 2 & 2 & 1 & 2 & 2 & 1 \end{pmatrix} & \begin{pmatrix} 6 \\ 3 \\ 0 \\ 3 \\ 1 \end{pmatrix} \end{pmatrix}$$

놈과 유사도

- 벡터와 행렬의 크기를 놈(Norm)으로 측정

- 벡터의 p차 놈

$$p\text{-차 놈: } \|x\|_p = \left(\sum_{i=1,d} |x_i|^p \right)^{\frac{1}{p}} \quad (2.3)$$

1차 ($p = 1$) 놈, 2차 ($p = 2$) 놈 Euclidean norm, 최대 ($p = \infty$) 놈 max norm

$$\text{최대 놈: } \|x\|_\infty = \max(|x_1|, |x_2|, \dots, |x_d|) \quad (2.4)$$

예) $x = (3 \ -4 \ 1)$ 일 때, 2차 놈은 $\|x\|_2 = (3^2 + (-4)^2 + 1^2)^{1/2} = 5.099$


- 행렬의 프robe니우스(Frobenius Norm) : 행렬의 크기를 측정

$$\text{프로베니우스 놈: } \|A\|_F = \left(\sum_{i=1,n} \sum_{j=1,m} a_{ij}^2 \right)^{\frac{1}{2}} \quad (2.6)$$

$$\text{예를 들어, } \left\| \begin{pmatrix} 2 & 1 \\ 6 & 4 \end{pmatrix} \right\|_F = \sqrt{2^2 + 1^2 + 6^2 + 4^2} = 7.550$$

- 1차 놈(Manhattan Distance, L1)과 2차 놈(Euclidean Distance, L2) 비교

크기의 차이



- 유사도(Similarity)와 거리(Distance)
 - 벡터를 기하학적으로 해석




그림 2-2 벡터를 기하학적으로 해석

- 코사인 유사도(Cosine Similarity)

$$\text{cosine_similarity}(\mathbf{a}, \mathbf{b}) = \frac{\mathbf{a}}{\|\mathbf{a}\|} \cdot \frac{\mathbf{b}}{\|\mathbf{b}\|} = \cos(\theta) \quad (2.7)$$

퍼셉트론의 해석

- 퍼셉트론 : 1958년 로젠블라트가 고안한 분류기(Classifier) 모델




그림 2-3 퍼셉트론의 구조와 동작

- 그림 2-3의 c의 파란 직선은 두 개의 부분공간을 나누는 결정직선(Decision Line)

w에 수직이고 원점으로부터 $\frac{T}{\|w\|_2}$ 만큼 떨어져 있음

- 동작을 수식으로 표현하면

$$o = \tau(\mathbf{w} \cdot \mathbf{x}), \quad \text{이때} \quad \tau(a) = \begin{cases} 1, & a \geq T \\ -1, & a < T \end{cases} \quad (2.8)$$

- 활성화 함수(Activation Function)으로는 계단함수(Step Function) 사용
- 3차원 특징공간은 결정평면(Decision Plane), 4차원 이상은 결정 초평면(Decision Hyperplane)
- 3차원 특징공간을 위한 퍼셉트론






그림 2-4 퍼셉트론의 예(3차원)

- 예제


$$\begin{aligned} \mathbf{a} &= (0,0)^T, \quad t_a = -1 \\ \mathbf{b} &= (1,0)^T, \quad t_b = 1 \\ \mathbf{c} &= (0,1)^T, \quad t_c = 1 \\ \mathbf{d} &= (1,1)^T, \quad t_d = 1 \end{aligned}$$



(a) OR 분류 문제



(b) OR 분류기로서 퍼셉트론




(c) 퍼셉트론은 선형 분류기

그림 4.3 퍼셉트론의 예

이 퍼셉트론은 $\mathbf{w} = (1,1)^T$, $b = -0.5$

따라서 결정 직선은 $d(\mathbf{x}) = x_1 + x_2 - 0.5$





▪ 샘플 a를 맞추나 보자? $y = \tau(\mathbf{w}^T \mathbf{c} + b) = \tau((1,1) \begin{pmatrix} 0 \\ 1 \end{pmatrix} - 0.5) = \tau(0.5) = 1$

▪ 나머지 샘플 b, c, d도 맞추는가?


○ AND 분류 문제는?

$$\begin{array}{cccc} \mathbf{a}=(0,0)^T & \mathbf{b}=(1,0)^T & \mathbf{c}=(0,1)^T & \mathbf{d}=(1,1)^T \\ t_a=-1 & t_b=-1 & t_c=1 & t_d=1 \end{array}$$




○ XOR 분류 문제는?

- 퍼셉트론은 75% 분류 한계
 - 이 한계를 어떻게 극복?
- 두 개의 퍼셉트론 (결정 직선) 사용



(a) XOR 분류 문제



(b) 두 개의 직선으로 해결


○ 다층 퍼셉트론(Multi-Layer Perceptron)

- 두 단계에 걸쳐 문제해결
 - 단계 1 : 원래 특징 공간을 새로운 공간으로 매핑
 - 단계 2 : 새로운 공간에서 분류
- XOR의 경우, 다음과 같은 조건을 활용



$$\left. \begin{array}{l} \mathbf{w}_1^T \mathbf{x} + b_1 > 0 \text{ 이고 } \mathbf{w}_2^T \mathbf{x} + b_2 > 0 \text{ 이면, } \mathbf{x} \in \omega_1 \\ \mathbf{w}_1^T \mathbf{x} + b_1 < 0 \text{ 이거나 } \mathbf{w}_2^T \mathbf{x} + b_2 < 0 \text{ 이면, } \mathbf{x} \in \omega_2 \end{array} \right\}$$

두 단계로 XOR 문제 해결

샘플	특징 벡터 (x)		첫 번째 단계		두 번째 단계
	x_1	x_2	퍼셉트론1	퍼셉트론2	퍼셉트론3
a	0	0	-1	+1	-1
b	1	0	+1	+1	+1
c	0	1	+1	+1	+1
d	1	1	-1	-1	-1




■ 다층 퍼셉트론을 활용한 XOR 분류 문제




세 개의 퍼셉트론과 이들을 연결하여 만든 다층 퍼셉트론

■ 다층 퍼셉트론의 구조(입력층, 은닉층, 출력층)



다층 퍼셉트론의 구조와 표기

- 출력이 여러 개인 퍼셉트론의 표현



출력은 벡터 $\mathbf{o} = (o_1, o_2, \dots, o_c)^T$ 로 표기

j 번째 퍼셉트론의 가중치 벡터를

$\mathbf{w}_j = (w_{j1}, w_{j2}, \dots, w_{jd})^T$ 와 같이 표기

그림 2-5 출력이 여러 개인 퍼셉트론

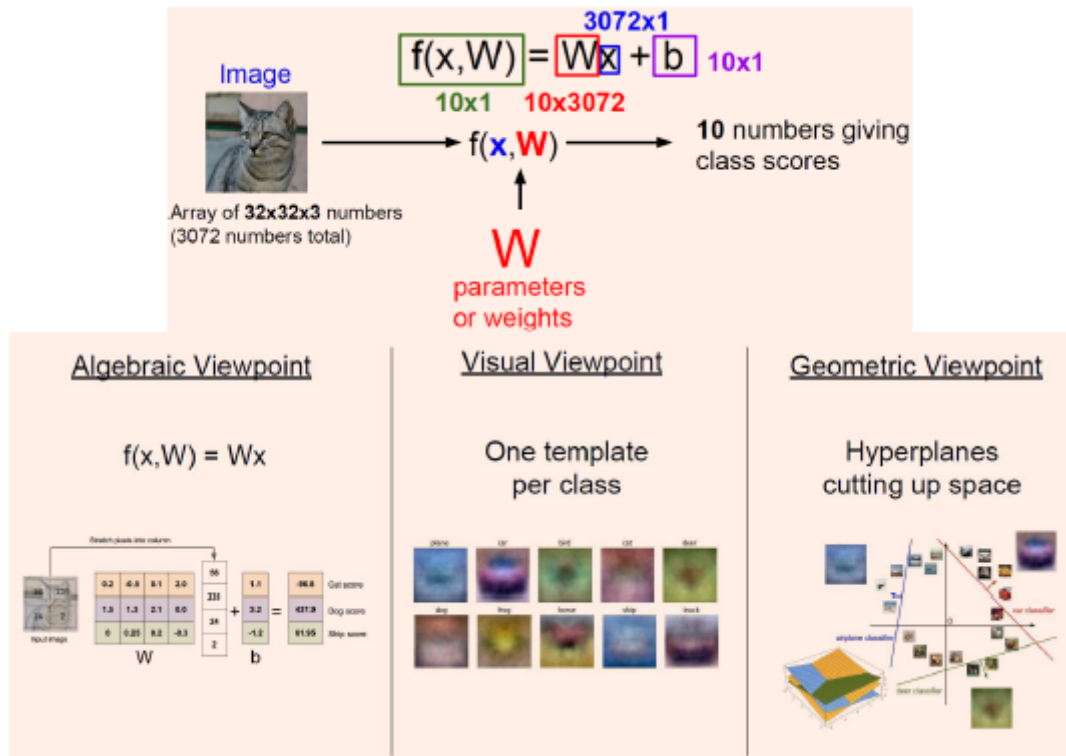
동작을 수식으로 표현하면,

$$\mathbf{o} = \tau \begin{pmatrix} \mathbf{w}_1 \cdot \mathbf{x} \\ \mathbf{w}_2 \cdot \mathbf{x} \\ \vdots \\ \mathbf{w}_c \cdot \mathbf{x} \end{pmatrix} \rightarrow \text{행렬로 간결하게 쓰면 } \mathbf{o} = \tau(\mathbf{W}\mathbf{x})$$

이때 $\mathbf{W} = \begin{pmatrix} \mathbf{w}_1^T \\ \mathbf{w}_2^T \\ \vdots \\ \mathbf{w}_c^T \end{pmatrix}$

가중치 벡터를 각 부류의 기준 벡터로 간주하면, c 개 부류의 유사도를 계산하는 셈

- 선형 분류기 이해



- 학습의 정의

- 추론(Inferring): 식(2.10)은 학습을 마친 알고리즘을 현장의 새로운 데이터에 적용했을 때 일어나는 과정

분류라는 과업: $\hat{\mathbf{o}} = \tau(\tilde{\mathbf{W}} \tilde{\mathbf{x}})$ (2.10)

- 학습(Learning): 훈련집합의 샘플에 대해 식(2.11)을 가장 잘 만족하는 \mathbf{W} 를 찾아내는 과정

학습이라는 과업: $\tilde{\mathbf{o}} = \tau(\tilde{\mathbf{W}} \tilde{\mathbf{x}})$ (2.11)

- 현대 기계 학습에서 퍼셉트론의 중요성

- 딥러닝은 퍼셉트론을 여러 층으로 확장하여 만들


선형결합과 벡터공간

- 벡터 : 공간상의 한 점으로 화살표 끝이 벡터의 좌표에 해당
- 선형결합이 만드는 벡터공간
 - 기저(basis)벡터 a와 b의 선형 결합(Linear Combination)

$$\mathbf{c} = \alpha_1 \mathbf{a} + \alpha_2 \mathbf{b}$$


(2,12)

- 선형결합으로 만들어지는 공간을 벡터공간(Vector Space)이라 부름




(a) 벡터에 스칼라 곱

그림 2-6 벡터의 연산




(b) 두 벡터의 덧셈



(a) 기저 벡터와 벡터공간


그림 2-7 벡터공간



(b) 정규직교 기저 벡터


역행렬

- 원리



(a) 역수의 원리

그림 2-9 역행렬



(b) 역행렬의 원리

- 정사각행렬 A의 역행렬 A^{-1}

$$A^{-1}A = AA^{-1} = I$$

- 예를 들어, $\begin{pmatrix} 2 & 1 \\ 6 & 4 \end{pmatrix}$ 의 역행렬은 $\begin{pmatrix} 2 & -0.5 \\ -3 & 1 \end{pmatrix}$

- 역행렬을 활용한 방정식 표현과 해

- 방정식: $\mathbf{Ax} = \mathbf{b}$ 의 확장
 - $\mathbf{A} \in \mathbb{R}^{m \times n}$: 알고 있는 행렬
 - $\mathbf{b} \in \mathbb{R}^m$: 알고 있는 벡터
 - $\mathbf{x} \in \mathbb{R}^n$: 알고 싶은 알지 못한 벡터

$$A_{1,:}\mathbf{x} = A_{1,1}x_1 + A_{1,2}x_2 + \cdots + A_{1,n}x_n = b_1$$

$$A_{2,:}\mathbf{x} = A_{2,1}x_1 + A_{2,2}x_2 + \cdots + A_{2,n}x_n = b_2$$

...

$$A_{m,:}\mathbf{x} = A_{m,1}x_1 + A_{m,2}x_2 + \cdots + A_{m,n}x_n = b_m$$

- 선형 방정식의 경우
 - 불능: 해 없음
 - 부정: 다수의 해 존재
 - 유일해 존재 \rightarrow 역행렬을 이용하여 해를 구함 \rightarrow

$$\begin{aligned}\mathbf{Ax} &= \mathbf{b} \\ \mathbf{A}^{-1}\mathbf{Ax} &= \mathbf{A}^{-1}\mathbf{b} \\ \mathbf{I}_n\mathbf{x} &= \mathbf{A}^{-1}\mathbf{b} \\ \mathbf{x} &= \mathbf{A}^{-1}\mathbf{b}\end{aligned}$$

- 정리

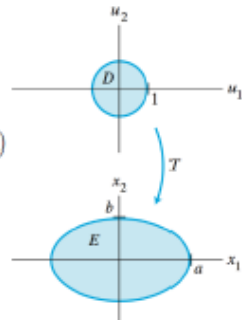
정리 2-1 다음 성질은 서로 필요충분조건이다.

- \mathbf{A} 는 역행렬을 가진다. 즉, 특이행렬이 아니다.
- \mathbf{A} 는 최대계수를 가진다.
- \mathbf{A} 의 모든 행이 선형독립이다.
- \mathbf{A} 의 모든 열이 선형독립이다.
- \mathbf{A} 의 행렬식은 0이 아니다.
- $\mathbf{A}^T\mathbf{A}$ 는 양의 정부호(positive definite) 대칭 행렬이다.
- \mathbf{A} 의 고윳값은 모두 0이 아니다.

- 행렬식(Determinant)

$$\left. \begin{aligned} \det \begin{pmatrix} a & b \\ c & d \end{pmatrix} &= ad - bc \\ \det \begin{pmatrix} a & b & c \\ d & e & f \\ g & h & i \end{pmatrix} &= aei + bfg + cdh - ceg - bdi - afh \end{aligned} \right\} (2.15)$$

예를 들어 $\begin{pmatrix} 2 & 1 \\ 6 & 4 \end{pmatrix}$ 의 행렬식은 $2 \cdot 4 - 1 \cdot 6 = 2$



{변환된 E 공간 부피}
= $|\det(\mathbf{A})| \cdot \{\text{원래 D 공간 부피}\}$

- 기하학적 의미

- 행렬식의 절대값은 주어진 행렬의 곱에 의한 공간의 확장 또는 축소로 볼 수 있음
 - If $\det(\mathbf{A}) = 0$, 하나의 차원을 따라 축소되어 공간의 부피를 잃게 됨

- If $\det(A) = 1$, 공간의 부피를 유지한 변환
- 차원에서의 기하학적인 예시
 - 2차원에서는 2개의 행 벡터가 이루는 평행사변형 넓이
 - 3차원에서는 3개의 행 벡터가 이루는 평행사각기둥의 부피




그림 2-10 행렬식의 기하학적 해석

• 정부호(Definiteness) 행렬

양의 정부호 행렬: $\mathbf{0}$ 이 아닌 모든 벡터 \mathbf{x} 에 대해, $\mathbf{x}^T \mathbf{A} \mathbf{x} > 0$

예를 들어, $\begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix}$ 는 $(x_1 \ x_2) \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = x_1^2 + 2x_2^2$ 이므로

$\begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix}$ 는 양의 정부호 행렬

○ 종류

양의 준정부호 positive semi-definite 행렬: $\mathbf{0}$ 이 아닌 모든 벡터 \mathbf{x} 에 대해, $\mathbf{x}^T \mathbf{A} \mathbf{x} \geq 0$

음의 정부호 negative definite 행렬: $\mathbf{0}$ 이 아닌 모든 벡터 \mathbf{x} 에 대해, $\mathbf{x}^T \mathbf{A} \mathbf{x} < 0$

음의 준정부호 negative semi-definite 행렬: $\mathbf{0}$ 이 아닌 모든 벡터 \mathbf{x} 에 대해, $\mathbf{x}^T \mathbf{A} \mathbf{x} \leq 0$

행렬 분해

• 분해(Decomposition)란?


- 정수 3717은 특성이 보이지 않지만, $3 \times 3 \times 7 \times 59$ 로 소인수분해하면 특성이 보이듯 분해하는 것

• 고유값(Eigenvalue)과 고유 벡터(Eigenvector)

고유 벡터 \mathbf{v} 와 고유값 λ

$$\mathbf{A} \mathbf{v} = \lambda \mathbf{v} \quad (2, 20)$$


- 2차원 공간에서의 고유값과 고유 벡터의 기하학적 해석



예를 들어, $\begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = 3 \begin{pmatrix} 1 \\ 1 \end{pmatrix}$ 이고 $\begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 1 \\ -1 \end{pmatrix} = 1 \begin{pmatrix} 1 \\ -1 \end{pmatrix}$ 이므로,

$$\lambda_1 = 3, \lambda_2 = 1 \text{ 이고 } \mathbf{v}_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \mathbf{v}_2 = \begin{pmatrix} 1 \\ -1 \end{pmatrix}$$

• 고유값의 효과



- 왼쪽: 원으로 표현된 단위 벡터 $\mathbf{u} \in \mathbb{R}^2$ 의 모든 점
- 오른쪽: 행렬 \mathbf{A} 의 곱에 의한 $\mathbf{A}\mathbf{u}$ 모든 점, \mathbf{A} 는 원을 고유 벡터 방향으로 고윳값만큼 크기 변환만 시킴
- 고윳값과 고유 벡터의 기하학적 해석

예제 2-5

[그림 2-12]의 반지름이 1인 원 위에 있는 4개의 벡터 $\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3, \mathbf{x}_4$ 가 $\mathbf{A} = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$ 에 의해 어떻게 변환되는지 살펴보자. 변환 후의 벡터를 각각 $\mathbf{x}'_1, \mathbf{x}'_2, \mathbf{x}'_3, \mathbf{x}'_4$ 로 표기한다.

$$\mathbf{x}'_1 = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix} = \begin{pmatrix} 3/\sqrt{2} \\ 3/\sqrt{2} \end{pmatrix}$$

$$\mathbf{x}'_2 = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$$

$$\mathbf{x}'_3 = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 1/\sqrt{2} \\ -1/\sqrt{2} \end{pmatrix} = \begin{pmatrix} 1/\sqrt{2} \\ -1/\sqrt{2} \end{pmatrix}$$

$$\mathbf{x}'_4 = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 0 \\ -1 \end{pmatrix} = \begin{pmatrix} -1 \\ -2 \end{pmatrix}$$

눈 여겨 볼 점은 \mathbf{A} 의 고유 벡터 $\begin{pmatrix} 1 \\ 1 \end{pmatrix}, \begin{pmatrix} 1 \\ -1 \end{pmatrix}$ 과 방향이 같은 \mathbf{x}_1 과 \mathbf{x}_3 이다. 이들은 변환 때문에 길이가 달라지더라도 방향은 그대로 유지한다. 식 (2.20)을 충실히 따르고 있다. 이때 길이의 변화는 고윳값 λ 에 따른다. 즉, \mathbf{x}_1 은 3배 만큼, \mathbf{x}_3 은 1배만큼 길이가 변한다. 나머지 \mathbf{x}_2 와 \mathbf{x}_4 는 길이와 방향이 모두 변한다. 파란 원 위에 있는 모든 점을 변환하면 빨간색의 타원이 된다. 파란 원 위에 존재하는 무수히 많은 점(벡터) 중에 방향이 바뀌지 않는 것은 고유 벡터에 해당하는 \mathbf{x}_1 과 \mathbf{x}_3 뿐이다.




그림 2-12 고유 벡터의 공간 변환

- 고유 분해(Eigen-decomposition)

$$A = Q\Lambda Q^{-1} \quad (2.21)$$

- Q 는 A 의 고유 벡터를 열에 배치한 행렬이고 Λ 는 고유값을 대각선에 배치한 대각행렬

$$\begin{aligned} A &= Q\Lambda Q^T \\ &= \begin{bmatrix} v_1 & v_2 & \cdots & v_n \end{bmatrix} \begin{bmatrix} \lambda_1 & 0 & 0 & 0 \\ 0 & \lambda_2 & 0 & 0 \\ 0 & 0 & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{bmatrix} \\ &= \begin{bmatrix} \lambda_1 v_1 & \lambda_2 v_2 & \cdots & \lambda_n v_n \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{bmatrix} \\ &= \lambda_1 v_1 v_1^T + \lambda_2 v_2 v_2^T + \cdots + \lambda_n v_n v_n^T \end{aligned}$$


- 예를 들어, $\begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix} \begin{pmatrix} 3 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 0.5 & 0.5 \\ 0.5 & -0.5 \end{pmatrix}$
- 고유 분해는 고유값과 해당 고유 벡터가 존재하는 정사각행렬에만 적용 가능
- 하지만, 기계 학습에서는 정사각행렬이 아닌 경우의 분해도 필요하므로

고유 분해는 한계를 가짐

- $n \times m$ 행렬 A 의 특잇값 분해(Singular Value Decomposition)

$$A = U\Sigma V^T \quad (2.22)$$


- 왼쪽 특이행렬 U 는 AA^T 의 고유 벡터를 열에 배치한 $n \times n$ 행렬
- 오른쪽 특이행렬 V 는 $A^T A$ 의 고유 벡터를 열에 배치한 $m \times m$ 행렬
- Σ 는 AA^T 의 고유값의 제곱근을 대각선에 배치한 $n \times m$ 대각행렬



예를 들어, A 를 4×3 행렬이라고 했을 때 다음과 같이 특잇값 분해가 된다.

$$\begin{aligned} A = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 2 & 2 \\ 3 & 1 & 0 \\ 1 & 0 & 2 \end{pmatrix} &= \begin{pmatrix} -0.1914 & -0.2412 & 0.1195 & -0.9439 \\ -0.5144 & 0.6990 & -0.4781 & -0.1348 \\ -0.6946 & -0.6226 & -0.2390 & 0.2697 \\ -0.4651 & 0.2560 & 0.8367 & 0.1348 \end{pmatrix} \\ &\begin{pmatrix} 3.7837 & 0 & 0 \\ 0 & 2.7719 & 0 \\ 0 & 0 & 1.4142 \\ 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} -0.7242 & -0.4555 & -0.5177 \\ -0.6685 & 0.2797 & 0.6891 \\ 0.1690 & -0.8452 & 0.5071 \end{pmatrix} \end{aligned}$$

- 기하학적 해석



- 정사각행렬이 아닌 행렬의 역행렬을 구하는데 사용됨

$$\begin{array}{ccc}
 \text{SVD} & & \text{Pseudoinverse} \\
 A = U \begin{pmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_s \\ & & & 0 \end{pmatrix} V^T & \longrightarrow & A^+ = V \begin{pmatrix} 1/\sigma_1 & & \\ & \ddots & \\ & & 1/\sigma_s & 0 \end{pmatrix} U^T
 \end{array}$$