

인공지능

[4. 딥러닝 기초]


소프트웨어융합대학
소프트웨어학부

본 자료는 해당 수업의 교육 목적으로만 활용될 수 있음.
일부 내용은 다른 교재와 논문으로부터 인용되었으며, 모든 저작권은 원 교재와 논문에 있음.

지난 장에는 뭐했지?



3.1 신경망 기초

■ 사람의 신경망과 인공 신경망 비교



3.2 퍼셉트론

■ 퍼셉트론의 구조, 동작, 학습



3.3 다층 퍼셉트론

■ 다층 퍼셉트론의 특징공간 변환






그림 3-11 퍼셉트론을 3개 결합했을 때 공간 변환

구 조	결정 구역	Exclusive-or	Classes with Meshed Regions	Most General Region Shapes
Single-layer j i 	Half Plane Bounded by Hyperplane			
Two-layer k j i 	Convex Open or Closed Regions			
Three-layer l k j i 	Arbitrary (Complexity limited by Number of Units)			

3.3 다층 퍼셉트론

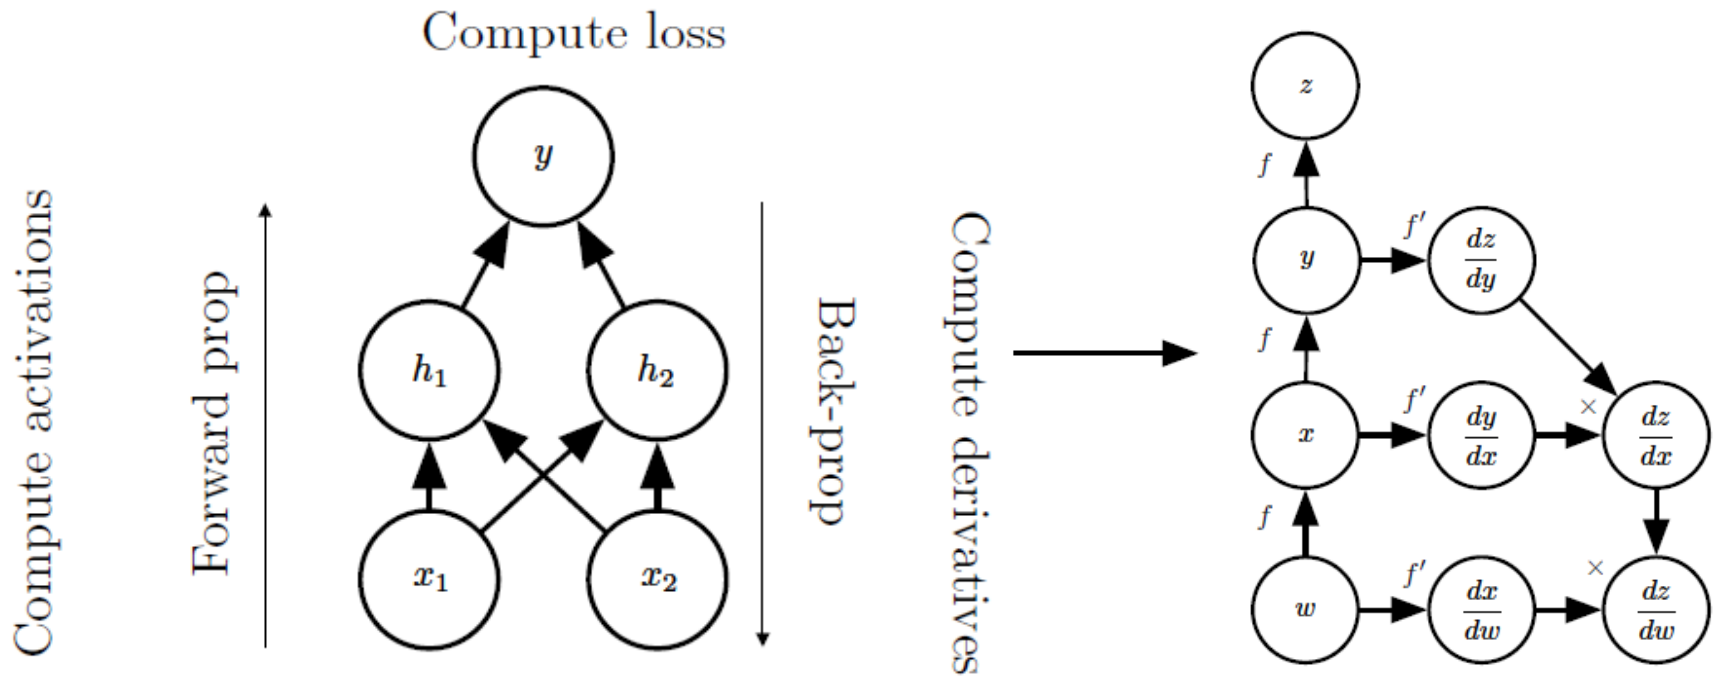
■ 은닉층은 특징 추출기

- 은닉층은 특징 벡터를 분류에 더 유리한 새로운 특징 공간으로 변환
- 현대 기계 학습에서는 특징 학습이라 feature learning 혹은 data-driven features 부름




3.3 다층 퍼셉트론

- 오류 역전파의 연산 그래프와 연쇄법칙 예



3.3 다층 퍼셉트론


■ 역전파 분해




3.3 다층 퍼셉트론

■ 역전파 주요 예


add gate: gradient distributor




mul gate: “swap multiplier”



copy gate: gradient adder



max gate: gradient router

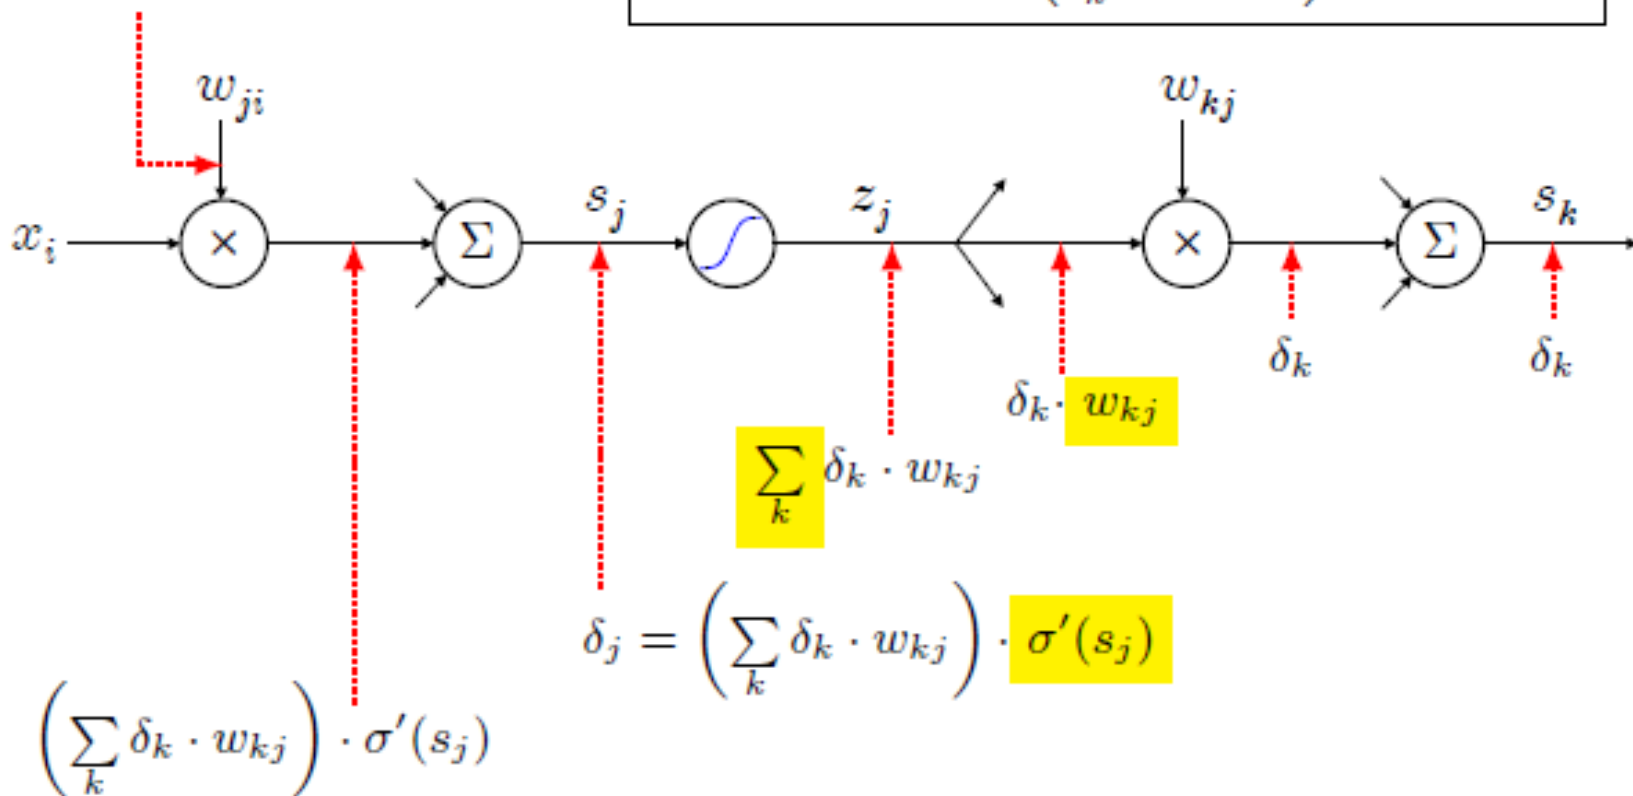


3.3 다층 퍼셉트론

■ 실제 역전파 예


computing $\frac{\partial \mathcal{E}}{\partial w_{ji}}$

$$\left(\sum_k \delta_k \cdot w_{kj} \right) \cdot \sigma'(s_j) \cdot x_i \Rightarrow \boxed{\frac{\partial \mathcal{E}}{\partial w_{ji}} = \delta_j \cdot x_i = \left(\sum_k \delta_k \cdot w_{kj} \right) \cdot \sigma'(s_j) \cdot x_i}$$



3.3 다층 퍼셉트론

■ 역전파의 간단한 구현



Forward pass:
Compute output

```
def f(w0, x0, w1, x1, w2):
```


```
    s0 = w0 * x0  
    s1 = w1 * x1  
    s2 = s0 + s1  
    s3 = s2 + w2  
    L = sigmoid(s3)
```

Backward pass:
Compute grads

```
    grad_L = 1.0  
    grad_s3 = grad_L * (1 - L) * L  
    grad_w2 = grad_s3  
    grad_s2 = grad_s3  
    grad_s0 = grad_s2  
    grad_s1 = grad_s2  
    grad_w1 = grad_s1 * x1  
    grad_x1 = grad_s1 * w1  
    grad_w0 = grad_s0 * x0  
    grad_x0 = grad_s0 * w0
```

3.3 다층 퍼셉트론

■ 배치, 미니배치, 스토캐스틱 경사하강법 비교



오늘 수업에는 뭐하지?

PREVIEW

■ 딥러닝deep learning

- 다층 퍼셉트론multilayer perceptron에 은닉층hidden layer을 여러 개 추가하면
깊은 신경망deep neural networks이 됨
- 딥러닝은 깊은 신경망을 학습시킴
- 딥러닝은 새로운 응용을 창출하고 인공지능 제품의 성능을 획기적으로 향상
→ 현대 기계 학습을 주도

각 절에서 다루는 내용

4.1절 딥러닝을 성공으로 이끈 여러 **기술 혁신 요소**를 소개한다.

4.2절 은닉층을 여러 개로 확장한 **깊은 다층 퍼셉트론의 구조**와 **학습 알고리즘**을 설명한다.

4.3절 **컨볼루션 신경망**의 컨볼루션과 풀링 연산을 상세히 설명한다.

4.4절 AlexNet, VGGNet, GoogLeNet, ResNet을 통해 **컨볼루션 신경망의 발전**을 소개한다.

4.5절 **생성 모델인 GAN**을 설명한다.

4.6절 통째 학습과 특징 학습을 살펴봄으로써 딥러닝이 **강력한 이유**를 설명한다.



4.1 딥러닝의 등장

- 4.1.1 딥러닝의 기술 혁신 요인
- 4.1.2 특징 학습의 부각

4.1 딥러닝의 등장


■ 배경

- 1980년대에 이미 깊은 신경망 아이디어 등장
- 하지만 실현 불가능 (당시, 깊은 신경망은 학습이 안 됨)
 - 그레이디언트 소멸^{vanishing gradient} 문제
 - 작은 훈련집합
 - 과다한 연산과 시간 소요 (값비싼 슈퍼컴퓨터)
- 일부 연구자들은 실망스러운 상황에서도 지속적인 연구
 - 학습률에 따른 성능 변화 양상
 - 모멘텀의 영향
 - 은닉 노드 수에 따른 성능 변화
 - 데이터 전처리의 영향
 - 활성화함수의 영향
 - 규제 기법의 영향 등

■ 딥러닝의 원리, 응용, 역사, 미래 전망을 살피려면 [LeCun2015] 참고

4.1 딥러닝의 등장

■ 그레이디언트 소멸 문제 gradient vanishing problem




4.1.1 딥러닝의 기술 혁신 요인

■ 요인

- **컨볼루션 신경망**convolutional neural networks (CNN)이 딥러닝의 가능성을 엮
 - 매개변수의 공유를 통해서 효율적인 학습 접근 제공
- + 계산은 단순한데 성능은 더 **좋은 활성화함수**
- + 과잉적합을 방지하는데 효과적인 **다양한 규제 기법**
- + 층별 **예비학습**pretraining 기법 개발
- + 값싼 **GPGPU**의 등장
- + 인터넷 덕분에 **학습 데이터 양과 질의 향상**

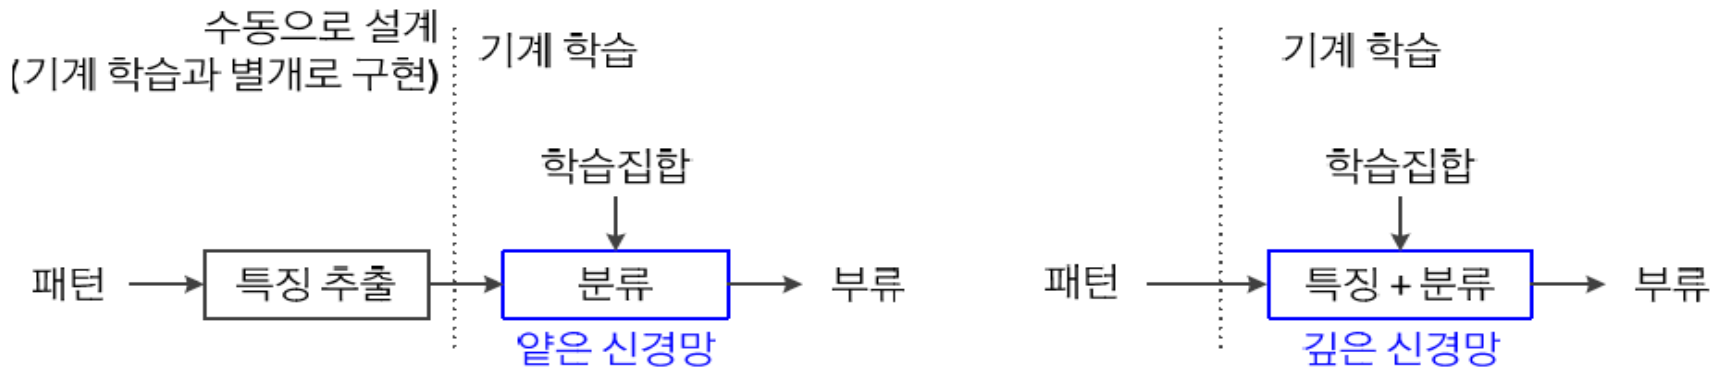
[LG경제연구원]



4.1.2 특징 학습의 부각

■ 기계 학습의 패러다임의 변화

- 고전적인 다층 퍼셉트론
 - 은닉층은 **특징 추출기** (3.3.4절의 [그림 3-16])
 - 얇은 구조 (제한적 특징 추출)이므로 가공하지 않은 획득한 원래 패턴을 그대로 입력하면 **낮은 성능**
 - 따라서 사람이 **수작업** 특징을 선택^{feature selection}하거나 추출^{feature extraction}하여 신경망에 입력함
- 현대 기계 학습 (딥러닝)
 - **데이터로부터 특징**^{data-driven features} **추출**하도록 학습 ← **특징 학습**^{feature learning}
 - 전체 특징을 신경망의 입력 ← **종단간 학습**^{end-to-end learning}



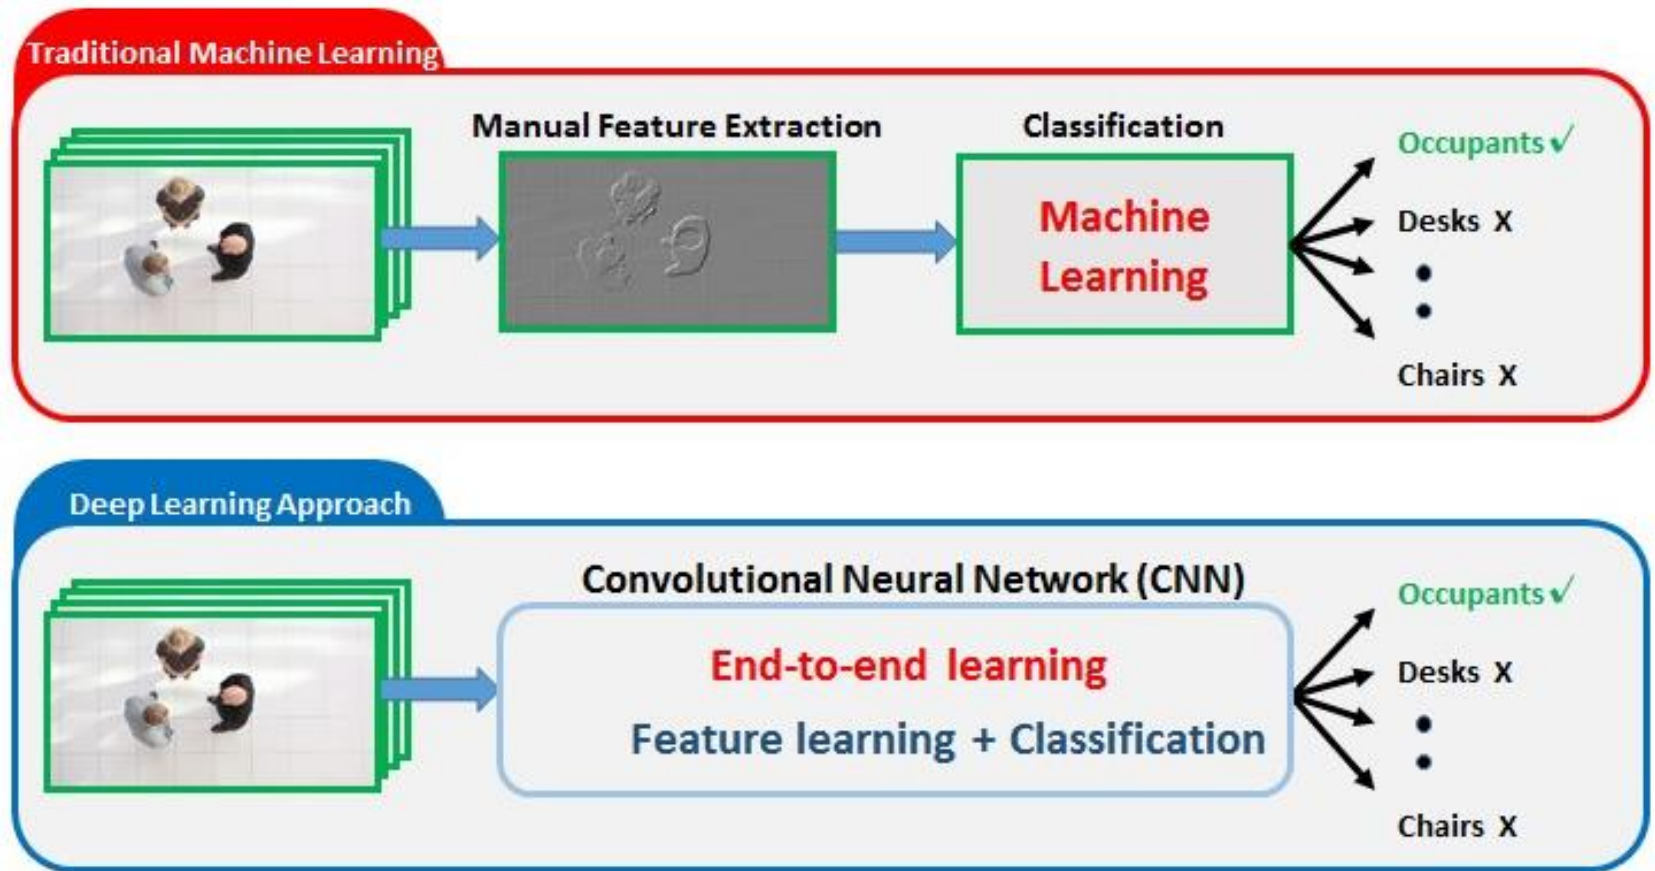
(a) 고전적 패러다임에서의 수작업 특징

(b) 딥러닝에서의 특징 학습

그림 4-1 기계 학습의 패러다임 변화

4.1.2 특징 학습의 부각

■ 고전적인 기계학습과 딥러닝 비교 예



4.1.2 특징 학습의 부각

■ 특징 학습^{feature learning} (또는 표현 학습^{representation learning})

- 낮은 단계 은닉층은 선이나 모서리와 같은 간단한 (저급) 특징 추출
- 높은 단계 은닉층은 추상적인 형태^{abstractive representation}의 복잡한 (고급) 특징을 추출
- 특징 학습이 강력해짐에 따라
 - 기존 응용에서 획기적인 성능 향상
 - 영상 인식, 음성 인식, 언어 번역 등
 - 새로운 응용 창출
 - 분류나 회귀뿐만 아니라 생성 모델이나 화소^{pixel} 수준의 영상 분할^{segmentation}
 - CNN과 LSTM의 협력 모델 ([그림 8-24]의 자연 영상에 주석 달기 응용) 등이 가능해짐




그림 4-2 깊은 신경망의 처리 절차

4.2 깊은 다층 퍼셉트론

- 4.2.1 구조와 동작
- 4.2.2 학습

4.2.1 구조와 동작

■ 깊은 다층 퍼셉트론 DMLP 혹은 deep MLP의 구조

- **입력층** ($d+1$ 개의 노드)과 **출력층** (c 개의 노드)
- $L-1$ 개의 **은닉층** (입력층은 0번째 은닉층, 출력층은 L 번째 은닉층으로 간주)
 - l 번째 은닉층의 노드 수를 n_l 로 표기




그림 4-3 깊은 MLP(DMLP)의 구조

4.2.1 구조와 동작

■ DMLP의 가중치 행렬

- u_{ji}^l 은 $l-1$ 번째 층의 i 번째 노드와 l 번째 층의 j 번째 노드를 연결하는 가중치
- $l-1$ 번째 층과 l 번째 층을 연결하는 가중치는 총 $(n_{l-1} + 1)n_l$ 개

$$\text{가중치 행렬: } \mathbf{U}^l = \begin{pmatrix} u_{10}^l & u_{11}^l & \cdots & u_{1n_{l-1}}^l \\ u_{20}^l & u_{21}^l & \cdots & u_{2n_{l-1}}^l \\ \vdots & \vdots & \ddots & \vdots \\ u_{n_l 0}^l & u_{n_l 1}^l & \cdots & u_{n_l n_{l-1}}^l \end{pmatrix}, l = 1, 2, \dots, L \quad (4.1)$$

■ DMLP의 동작

- MLP의 동작을 나타내는 식 (3.12)를 보다 많은 단계로 확장한 것

$$\mathbf{o} = \mathbf{f}(\mathbf{x}) = \mathbf{f}_L \left(\cdots \mathbf{f}_2 \left(\mathbf{f}_1(\mathbf{x}) \right) \right) \quad (4.2)$$

4.2.1 구조와 동작

■ 동작을 구체적으로 쓰면,

- 입력층의 특징 벡터를 내부 표현으로 바꾸어 쓰면,

$$\mathbf{z}^0 = (z_0, z_1, z_2, \dots, z_{n_0})^T = (1, x_1, x_2, \dots, x_d)^T \quad (4.3)$$

- l 번째 층의 j 번째 노드가 수행하는 연산

l 번째 은닉층의 j 번째 노드의 연산:

$$z_j^l = \tau_l(s_j^l)$$

이때 $s_j^l = \mathbf{u}_j^l \mathbf{z}^{l-1}$ 이고,

$$\mathbf{z}^{l-1} = (1, z_1^{l-1}, z_2^{l-1}, \dots, z_{n_{l-1}}^{l-1})^T, \quad \mathbf{u}_j^l = (u_{j0}^l, u_{j1}^l, \dots, u_{jn_{l-1}}^l)$$

(4.4)

- 행렬 표기를 이용하여 l 번째 층의 연산 전체를 쓰면,

$$l\text{번째 층의 연산: } \mathbf{z}^l = \boldsymbol{\tau}_l(\mathbf{U}^l \mathbf{z}^{l-1}), \quad 1 \leq l \leq L \quad (4.5)$$

4.2.2 학습

■ DMLP 학습은 3장의 MLP 학습과 유사

- DMLP는 그레이디언트 계산과 가중치 갱신을 더 많은 단계에 걸쳐 수행

■ 오류 역전파 알고리즘

- L 번째 층(출력층)의 그레이디언트 계산

$$\delta_k^L = \tau'_L(s_k^L)(y_k - o_k), \quad 1 \leq k \leq c \quad (4.6)$$

$$\frac{\partial J}{\partial u_{kr}^L} = -\delta_k^L z_r^{L-1}, \quad 0 \leq r \leq n_{L-1}, 1 \leq k \leq c \quad (4.7)$$

- $l+1$ 번째 층의 정보를 이용하여 l 번째 층의 그레이디언트 계산 ($l=L-1, L-2, \dots, 1$)

$$\delta_j^l = \tau'_l(s_j^l) \sum_{p=1}^{n_{l+1}} \delta_p^{l+1} u_{pj}^{l+1}, \quad 1 \leq j \leq n_l \quad (4.8)$$

$$\frac{\partial J}{\partial u_{ji}^l} = -\delta_j^l z_i^{l-1}, \quad 0 \leq i \leq n_{l-1}, 1 \leq j \leq n_l \quad (4.9)$$

4.2.2 학습

- 식 (4.6)~식 (4.9)의 오류 역전파 공식을 이용한 학습 알고리즘

알고리즘 4-1 DMLP를 위한 미니배치 스토캐스틱 경사 하강법

입력: 훈련집합 \mathbb{X} 와 \mathbb{Y} , 학습률 ρ , 미니배치 크기 t

출력: 가중치 행렬 $\mathbf{U}^l, l = 1, 2, \dots, L$

```
1   $\mathbf{U}^l, l = 1, 2, \dots, L$ 을 초기화한다.
2  repeat
3       $\mathbb{X}$ 와  $\mathbb{Y}$ 에서  $t$ 개의 샘플을 무작위로 뽑아 미니배치  $\mathbb{X}'$ 와  $\mathbb{Y}'$ 를 만든다.
4      for ( $l=1$  to  $L$ )  $\Delta \mathbf{U}^l = \mathbf{0}$ 
5          for ( $\mathbb{X}'$ 의 샘플 각각에 대해)
6              현재 처리하는 샘플을  $\mathbf{x} = (x_0, x_1, x_2, \dots, x_d)^T$ ,  $\mathbf{y} = (y_1, y_2, \dots, y_c)^T$ 라 표기한다.
7               $x_0, z_0^1, z_0^2, \dots, z_0^L$ 을 1로 설정한다.
8              // 전방 계산
9               $\mathbf{x}$ 를  $\mathbf{z}^0$ 에 대입한다. // 식 (4.3)
10             for ( $l=1$  to  $L$ ) // 왼쪽 층에서 오른쪽 층으로 진행하면서 전방 계산
11                 for ( $j=1$  to  $n_l$ ) // 각 노드에 대해
12                      $s_j^l = \mathbf{u}_j^l \mathbf{z}^{l-1}$  // 식 (4.4)
13                      $z_j^l = \tau_l(s_j^l)$  // 식 (4.4)
14                 // 오류 역전파의 단계 1: 그레이디언트 계산
15                 for ( $k=1$  to  $c$ )  $\delta_k^L = \tau'_L(s_k^L)(y_k - o_k)$  // 식 (4.6)
16                 for ( $k=1$  to  $c$ ) for ( $r=0$  to  $n_{L-1}$ )  $\Delta u_{kr}^L = \Delta u_{kr}^L + (-\delta_k^L z_r^{L-1})$ 
17                 for ( $l=L-1$  to 1) // 오른쪽 층에서 왼쪽 층으로 진행하면서 오류 역전파
18                     for ( $j=1$  to  $n_l$ )  $\delta_j^l = \tau'_l(s_j^l) \sum_{p=1}^{n_{l+1}} \delta_p^{l+1} u_{pj}^{l+1}$  // 식 (4.8)
19                     for ( $j=1$  to  $n_l$ ) for ( $i=0$  to  $n_{l-1}$ )  $\Delta u_{ji}^l = \Delta u_{ji}^l + (-\delta_j^l z_i^{l-1})$ 
20                 // 오류 역전파의 단계 2: 가중치 갱신
21             for ( $l=L$  to 1)
22                 for ( $j=1$  to  $n_l$ ) for ( $i=0$  to  $n_{l-1}$ )  $u_{ji}^l = u_{ji}^l - \rho \left( \frac{1}{t} \right) \Delta u_{ji}^l$ 
23 until (멈춤 조건)
```

4.2.2 학습

■ 역사적 고찰

■ 학습 알고리즘의 주요 개선

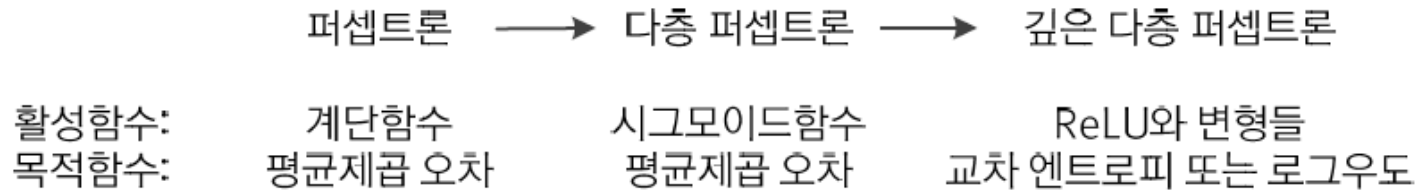


그림 4-4 다층 퍼셉트론의 역사적 발전 양상

■ CNN의 부상



• 예) MNIST 인식 경쟁

- 2010년 784-2500-2000-1500-1000-500-10 구조의 DMLP 0.35% 오류율
- 2011년 CNN 0.35% 오류율
- 2012년 35개 CNN을 이용한 앙상블 모델 0.23% 오류율 [Ciresan2012]

• 예) ILSVRC 영상 인식 경쟁 ([그림 4-30]): CNN이 DMLP보다 확연히 우월

4.3 컨볼루션 신경망

■ 영상 인식의 예



What the computer sees

image classification

82% cat
15% dog
2% hat
1% mug

4.3 컨볼루션 신경망

■ 4.3.1 컨볼루션층 (CONV)


- 선형함수인 컨볼루션과 비선형 함수인 활성화함수의 조합

■ 4.3.2 풀링층 (POOL)

- 컨볼루션의 얻어진 특징을 통계적으로 압축

■ 4.3.3 전체 구조

- CONV-POOL-...-FC



4.3 컨볼루션 신경망

■ 오늘날, 영상 분야에서 다양하게 활용됨

분류classification



검색retrieval




Figures copyright Alex Krizhevsky, Ilya Sutskever, and Geoffrey Hinton, 2012. Reproduced with permission.

검출detection



Figures copyright Shaoqing Ren, Kaiming He, Ross Girshick, Jian Sun, 2015. Reproduced with permission.

분할segmentation



Figures copyright Clement Farabet, 2012. Reproduced with permission.

[Farabet et al., 2012]

4.3 컨볼루션 신경망 CNN(convolutional neural network)

■ DMLP와 CNN의 비교

■ DMLP


- 완전 연결 fully connection 구조로 높은 복잡도
- 학습이 매우 느리고 과잉적합 우려

■ CNN


- 컨볼루션 연산을 이용한 부분연결 (희소 연결) 구조로 복잡도 크게 낮춤
- 컨볼루션 연산은 좋은 특징 추출

■ CNN

- 격자 grid 구조 (영상, 음성 등)를 갖는 데이터에 적합
- 수용장 receptive field은 인간시각과 유사
- 가변 크기의 입력 처리 가능



(a) DMLP(완전연결)



(b) CNN(부분연결)

그림 4-5 CNN의 부분연결과 수용장

4.3 컨볼루션 신경망CNN(convolutional neural network)

■ CNN의 완전 연결 신경망fully connected neural networks과 차별

- 각 층의 입출력의 특징형상 유지
- 영상의 **공간 정보**를 유지하면서 공간적으로 **인접한 정보의 특징을 효과적으로 인식**
- 학습에 의해 결정된 **복수의 커널들 (혹은 필터들)**에 대응되는 특징들을 **추출하는 층을** 가짐
- 추출된 영상의 **특징을 요약하고 강화하는 층을** 가짐
- 각 커널 (필터)은 **파라미터를 공유함**으로써 완전 연결 신경망 대비 **학습 파라미터가 매우 적음**

4.3.1 컨볼루션층

■ 컨볼루션convolution 연산

- 컨볼루션은 해당하는 요소끼리 곱하고 결과를 모두 더하는 **선형 연산 (합성곱)**
- 식 (4.10)과 식 (4.11)에서 u 는 **커널kernel** (혹은 **필터filter**), z 는 **입력**, s 는 **출력 (특징 맵feature map)**
 - 영상에서 **특징을 추출하기 위한 용도로 사용됨 (=공간 필터spatial filtering)**


※필터: 무언가를 걸러내는 도구

$$s(i) = z \circledast u = \sum_{x=-(h-1)/2}^{(h-1)/2} z(i+x)u(x) \quad (4.10)$$

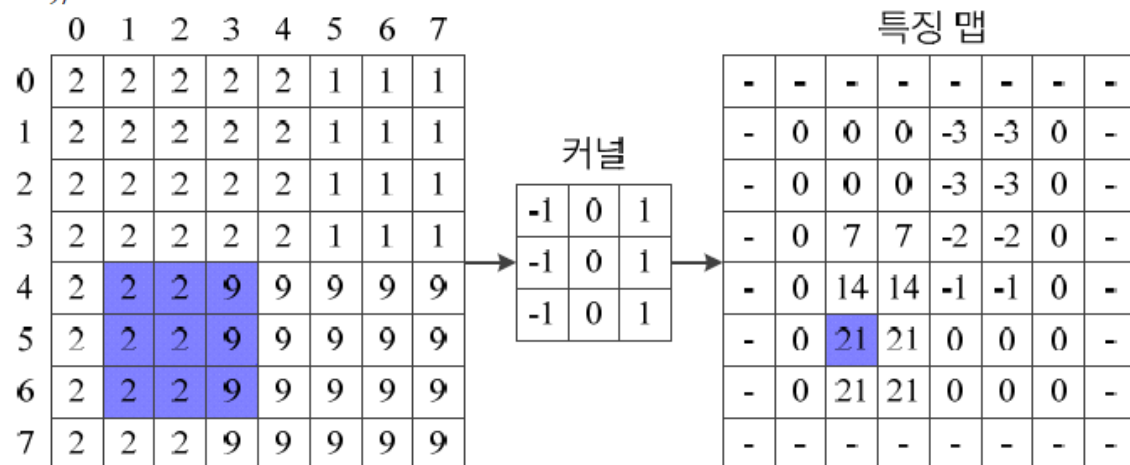
← 1차원 입력

$$s(j,i) = z \circledast u = \sum_{y=-(h-1)/2}^{(h-1)/2} \sum_{x=-(h-1)/2}^{(h-1)/2} z(j+y, i+x)u(y,x) \quad (4.11)$$

← 2차원 입력




(a) 1차원 컨볼루션



(b) 2차원 컨볼루션



4.3.1 컨볼루션층

■ 1차원 컨볼루션 연산의 예



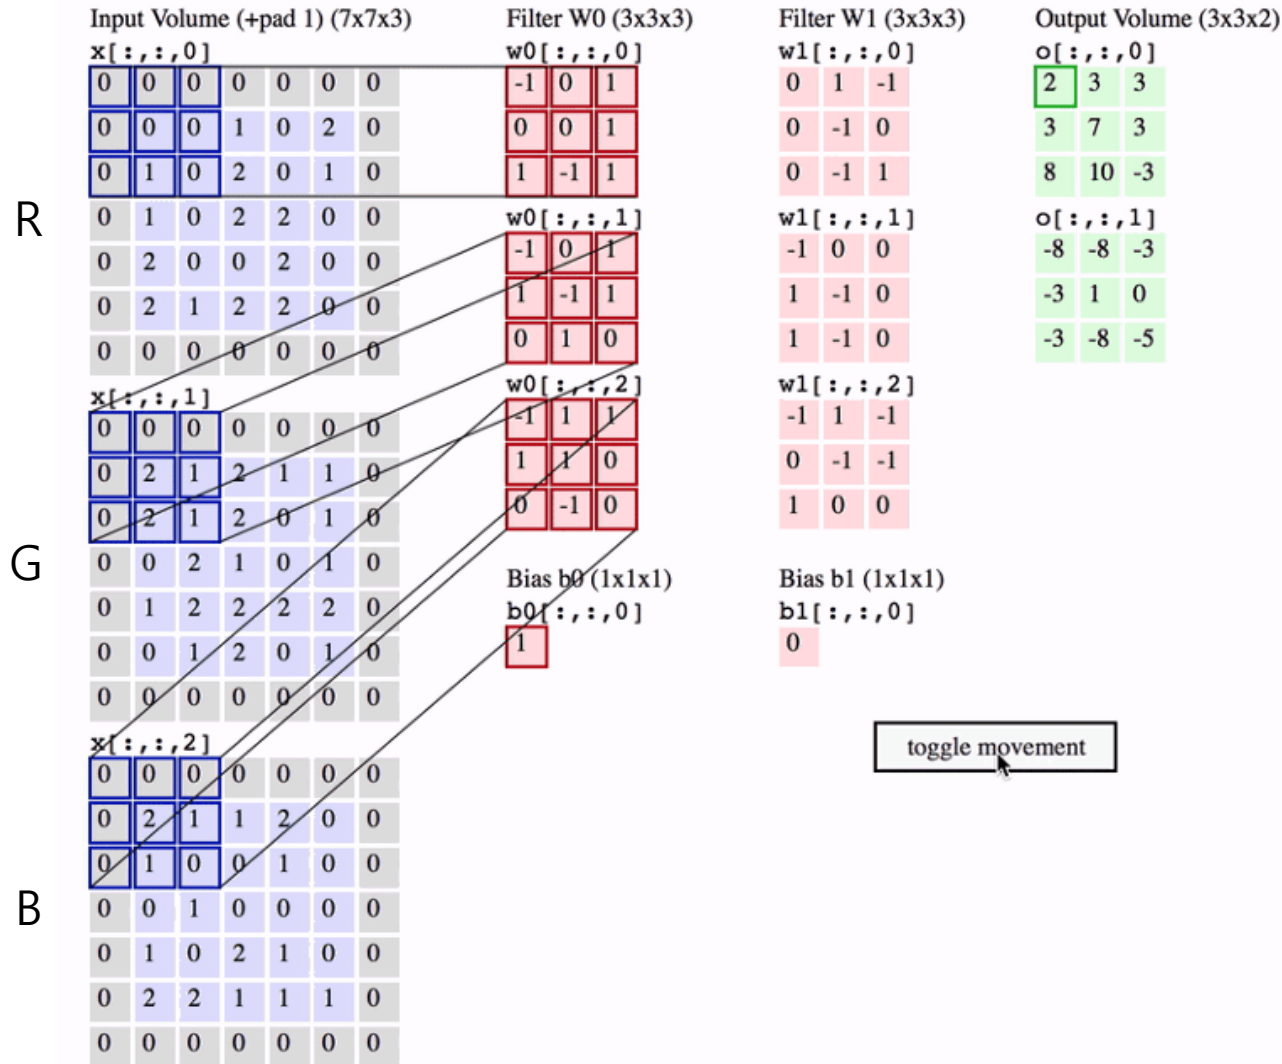
4.3.1 컨볼루션층

■ 2차원 컨볼루션 연산의 예



4.3.1 컨볼루션층

■ 3차원 (혹은 채널channel) 컨볼루션 연산의 예



4.3.1 컨볼루션층


■ 영상에서의 컨볼루션(convolution) 연산 예

$$\begin{Bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{Bmatrix} \times$$

Horizontal



=



$$\begin{Bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{Bmatrix} \times$$

Vertical



=



4.3.1 컨볼루션층

- 영상에서의 다수의 컨볼루션(convolution) 연산 예



Input

커널의 값에 따라 커널이 추출하는 특징이 달라짐

4.3.1 컨볼루션층

- 영상에서의 ReLU (활성함수) 연산의 예

Input Feature Map

Rectified Feature Map

ReLU
➔

Black = negative; white = positive values


Only non-negative values

활성화된 특징 맵


4.3.1 컨볼루션층

■ 덧대기 padding

- 가장자리에서 영상의 크기가 줄어드는 효과 방지 (각 층의 입출력의 특징 **형상 유지**)




(a) 0 덧대기



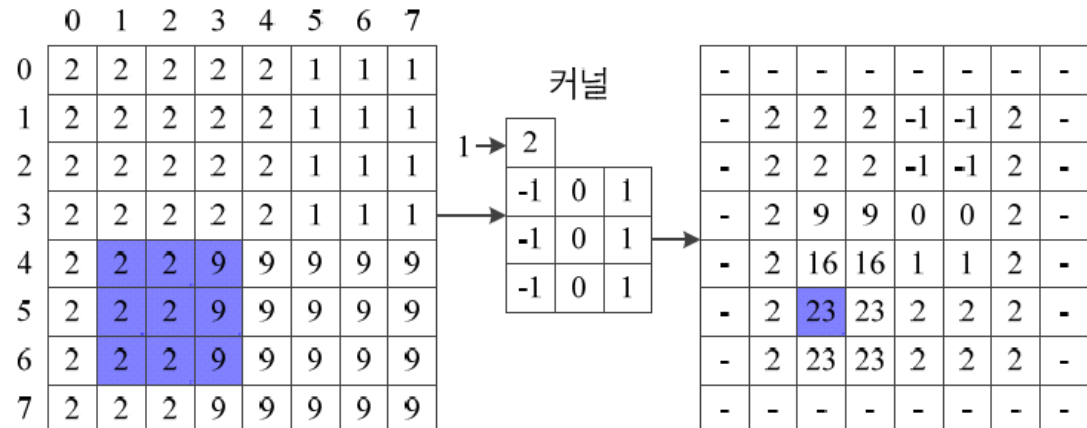
(b) 복사 덧대기

그림 4-7 덧대기(회색 노드가 덧댄 노드)

■ 바이어스 추가



(a) 1차원 컨볼루션



(b) 2차원 컨볼루션

그림 4-8 바이어스

4.3.1 컨볼루션층

■ 가중치 공유 weight sharing 혹은 parameter sharing (묶인 가중치)

- 모든 노드가 동일한 커널(kernel)을 사용
(즉 가중치를 공유)하므로 매개변수는 3개에 불과
- 모델의 복잡도가 크게 낮아짐




그림 4-9 CNN의 가중치 공유

4.3.1 컨볼루션층

■ 다중 특징 맵 추출

- 커널의 값에 따라 커널이 추출하는 특징이 달라짐
- 예) $\begin{pmatrix} -1 & 0 & 1 \\ -1 & 0 & 1 \\ -1 & 0 & 1 \end{pmatrix}$: 수직방향, $\begin{pmatrix} -1 & -1 & -1 \\ 0 & 0 & 0 \\ 1 & 1 & 1 \end{pmatrix}$: 수평방향 선 혹은 모서리 추출
- 따라서 하나의 커널만 사용하면 너무 빈약한 특징이 추출됨
- [그림 4-10]은 3개 커널을 사용하여 3개 특징 맵을 추출하는 상황
- 실제로는 수십~수백 개의 커널을 사용

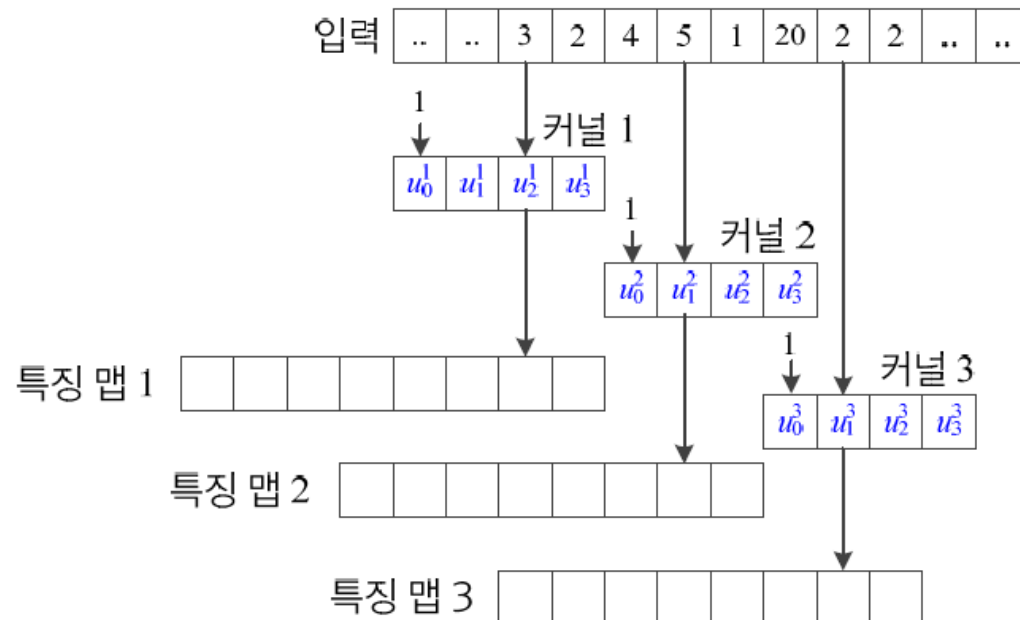


그림 4-10 다중 특징 맵 추출

4.3.1 컨볼루션층

■ 특징 학습

- 커널을 사람이 설계하지 않고, 학습으로 찾음

- u_i^k 는 k 번째 커널의 i 번째 매개변수

- 예) 2차원 영상이 7*7 커널을 64개 사용한다면,

학습은 $(7*7+1)*64=3200$ 개의 매개변수를 찾아내야 함

- DMLP와 마찬가지로 오류 역전파로 커널을 학습함

4.3.1 컨볼루션층

■ 컨볼루션 연산에 따른 CNN의 특성

- 이동에 동변 (신호가 이동하면 이동 정보가 그대로 특징 맵에 반영)

→ 영상 인식에서 물체 이동이나 음성 인식에서 발음 지연에 효과적으로 대처




그림 4-11 CNN의 이동에 동변한 특성

■ 병렬분산 구조

- 각 노드는 독립적으로 계산 가능하므로 병렬 구조
- 노드는 깊은 층을 거치면서 전체에 영향을 미치므로 분산 구조





그림 4-12 CNN의 병렬 분산 구조


4.3.1 컨볼루션층

■ 큰 보폭^{stride}에 의한 다운샘플링

- 지금까지는 모든 화소에 커널 적용 → 보폭을 1로 설정한 셈
- [그림 4-13]은 보폭이 2인 상황
- 일반적으로 보폭이 k 이면, k 개 마다 하나씩 샘플링하여 커널 적용
→ 2차원 영상의 경우 특징 맵이 $1/k^2$ 로 작아짐



(a) 1차원 데이터(예: 음성)



(b) 2차원 데이터(예: 영상)

그림 4-13 보폭이 2인 컨볼루션 연산

4.3.1 컨볼루션층

■ 텐서에 적용

- 3차원 이상의 구조에도 적용 가능
 - 예) RGB 컬러 영상은 $3*m*n$ 의 3차원 텐서 ([그림 4-14])

3*3*3 입력 영상




그림 4-14 텐서의 컨볼루션 연산(0 덧대기 적용)


- 특징 맵의 회색 노드의 계산 예시

$$\underbrace{\begin{pmatrix} 0 & 0 & 0 \\ 0 & 1 & 1 \\ 0 & 2 & 1 \end{pmatrix}}_R \underbrace{\begin{pmatrix} 0 & 0 & 0 \\ 0 & 2 & 2 \\ 0 & 1 & 0 \end{pmatrix}}_G \underbrace{\begin{pmatrix} 0 & 0 & 0 \\ 0 & 0 & 3 \\ 0 & 1 & 0 \end{pmatrix}}_B \otimes \underbrace{\begin{pmatrix} 0 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{pmatrix}}_{c_1} \underbrace{\begin{pmatrix} 0 & 2 & 0 \\ 0 & 2 & 0 \\ 0 & 2 & 0 \end{pmatrix}}_{c_2} \underbrace{\begin{pmatrix} 1 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 1 \end{pmatrix}}_{c_3} = 9$$

4.3.1 컨볼루션층

■ 3차원 구조의 데이터에 적용

- 채널이 k 개인 3차원 격자 구조([그림 4-15(a)])
 - [그림 4-14]를 블록 형태로 다시 그린 것 (예, RGB 컬러 영상)



(a) 다중채널 데이터(예: RGB 컬러 영상)

(b) 3차원 데이터(예: 동영상, MRI 뇌 영상)


그림 4-15 텐서의 컨볼루션 연산(직육면체로 표현하기)

- 4차원 텐서로 표현하는 데이터 ([그림 4-15(b)])
 - 예) 컬러 동영상 ($3*s*m*n$), MRI 뇌영상 ($1*s*m*n$)
 - $k*h*h*h$ 커널을 $s*m*n$ 공간을 이동하면서 적용


4.3.2 풀링층

풀링 pooling 연산

- [그림 4-16]은 최대 풀링 max pooling 예
- 최대 풀링, 평균 풀링, 가중치 평균 풀링 등
- 보폭을 크게 하면 다운샘플링 downsampling 효과





(a) 보폭 1



(b) 보폭 2

그림 4-16 최대 풀링



4.3.2 풀링층

■ 풀링 연산의 특성

- 풀링은 상세 내용에서 **요약** 혹은 평균 등의 통계적 **대표성**을 추출함
- 매개변수가 없음
- 특징 맵의 수를 그대로 유지함 (크기X)
- 작은 변화에 둔감 → 물체 인식이나 영상 검색 등에 효과적임

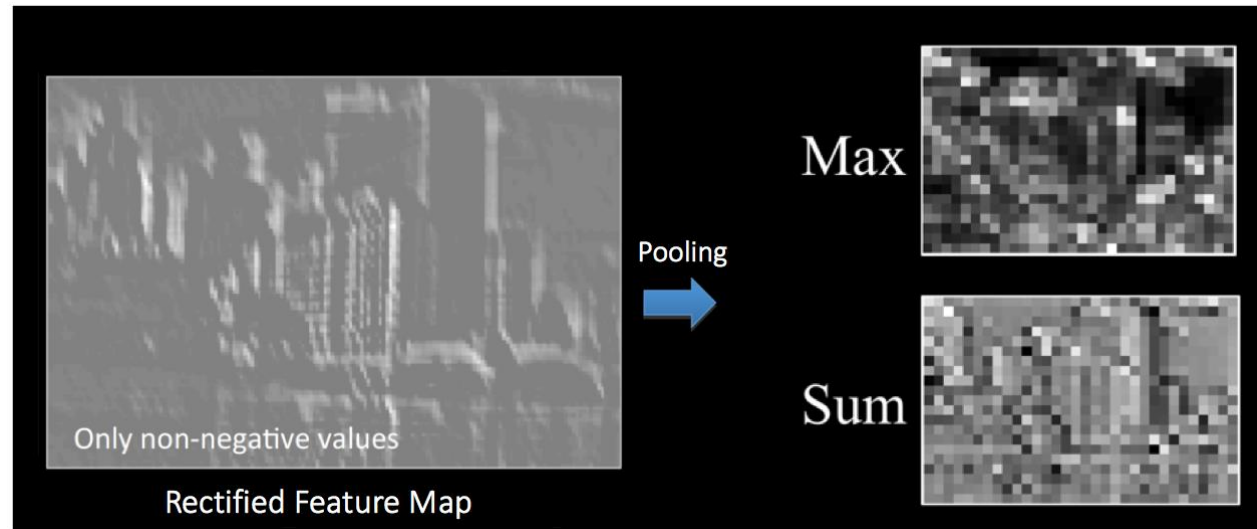



그림 4-17 작은 이동에 둔감한 최대 풀링

4.3.3 전체 구조

■ 빌딩 블록 building block

- CNN은 빌딩 블록을 이어 붙여 **깊은 구조로 확장**
- [그림 4-18]은 전형적인 빌딩블록: **컨볼루션층** → **활성함수** (주로 ReLU 사용) → **풀링층**
- 다중 커널을 사용하여 다중 특징 맵을 추출함

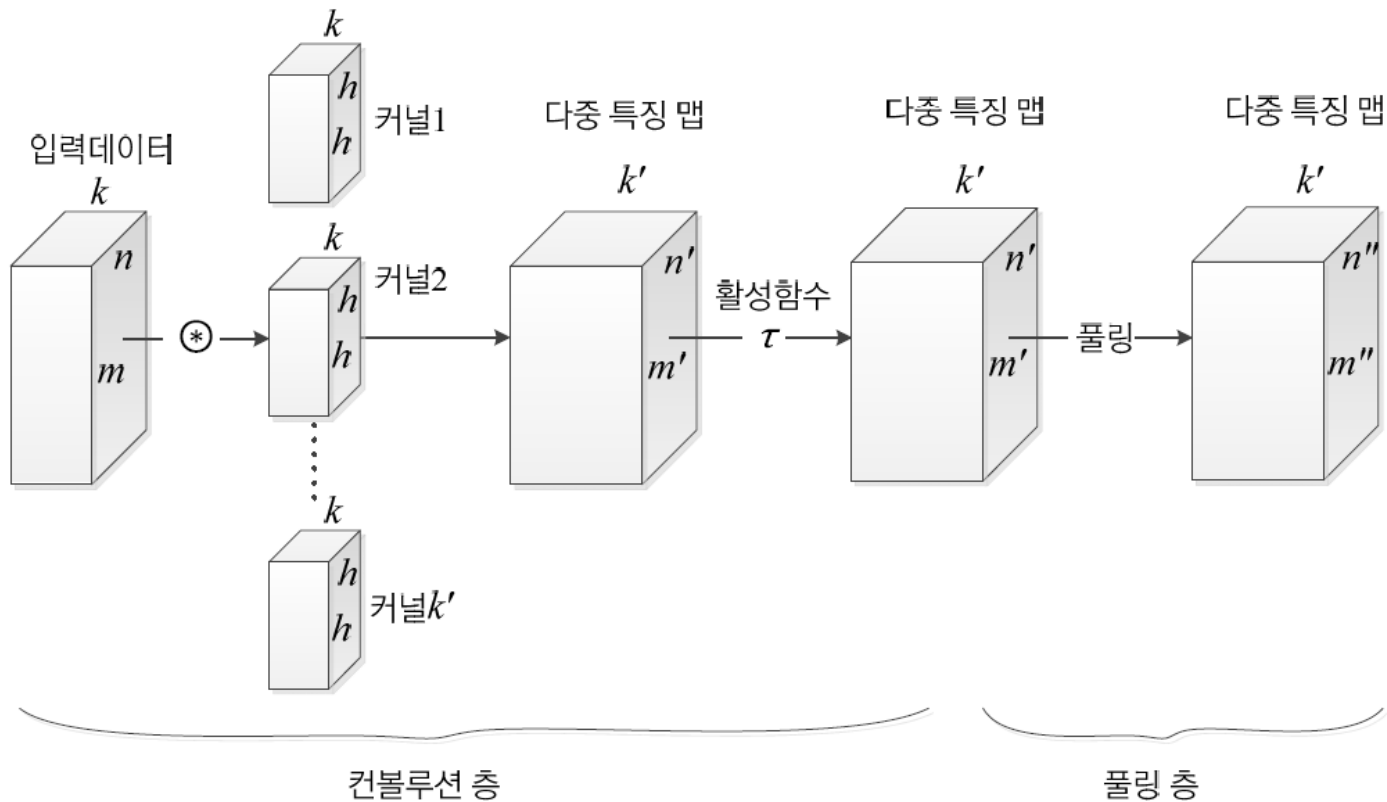


그림 4-18 CNN의 빌딩블록

4.3.3 전체 구조

■ 출력의 크기와 매개변수의 수

- 입력: $W1 \times H1 \times D1$
- K 개 $F \times F$ 커널, 보폭 S , 덧대기 P

→ 출력의 크기: $W2 \times H2 \times D2$

$$W2 = (W1 - F + 2P) / S + 1$$

$$H2 = (H1 - F + 2P) / S + 1$$

$$D2 = K$$

→ 매개변수의 수:

커널마다 $(F \times F \times D1)$ 개의 가중치와 1개의 바이어스를 가짐
따라서, 전체 매개변수의 수는 $(F \times F \times D1)K + K$

- 일반적으로 $F=2$, $S=2$ 혹은 $F=3$, $S=2$ 를 사용함

4.3.3 전체 구조

■ 초창기 CNN 사례로서 LeNet-5

- 특징 추출: CONV-POOL-CONV-POOL-CONV의 다섯 층을 통해 28×28 명암 영상을 120차원의 특징 벡터로 변환
 - 평균 풀링
- 분류: 은닉층이 하나인 MLP
- CNN의 첫 번째 성공사례: 필기 숫자 인식기 만들어 수표 인식 자동화 시스템 구현

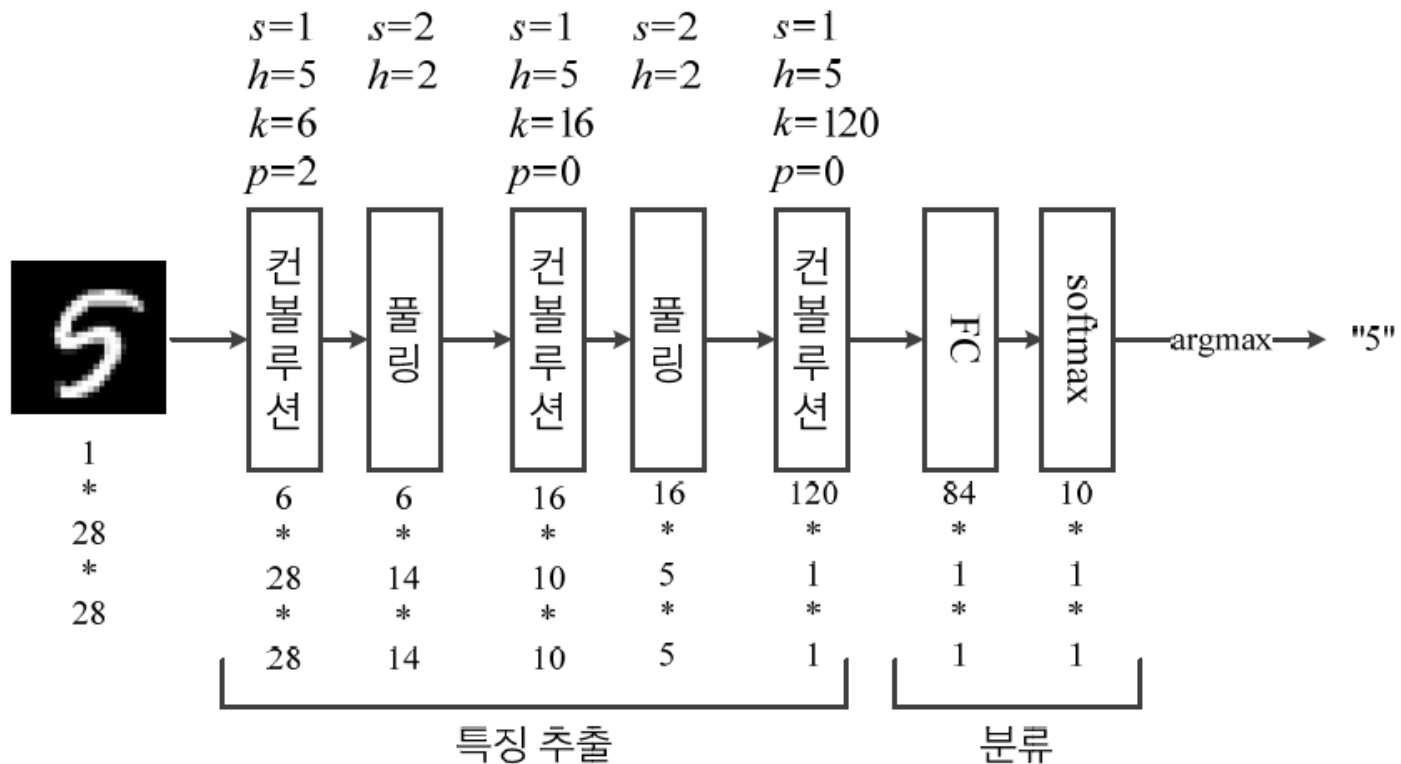


그림 4-19 LeNet-5 구조

4.3.3 전체 구조

■ 가변 크기의 데이터 다루기

- DMLP는 특징 벡터의 크기가 달라지면 연산 불가능
- CNN은 가변 크기를 다룰 수 있는 장점
 - 컨볼루션층에서 보폭을 조정한다거나, 풀링층에서 커널이나 보폭을 조정하여 특징 맵 크기를 조절

4.4 컨볼루션 신경망 사례연구

- 4.4.1 AlexNet
- 4.4.2 VGGNet
- 4.4.3 GoogLeNet
- 4.4.4 ResNet

4.4 컨볼루션 신경망 사례연구

■ 영상 분류 image classification: 도전적 문제

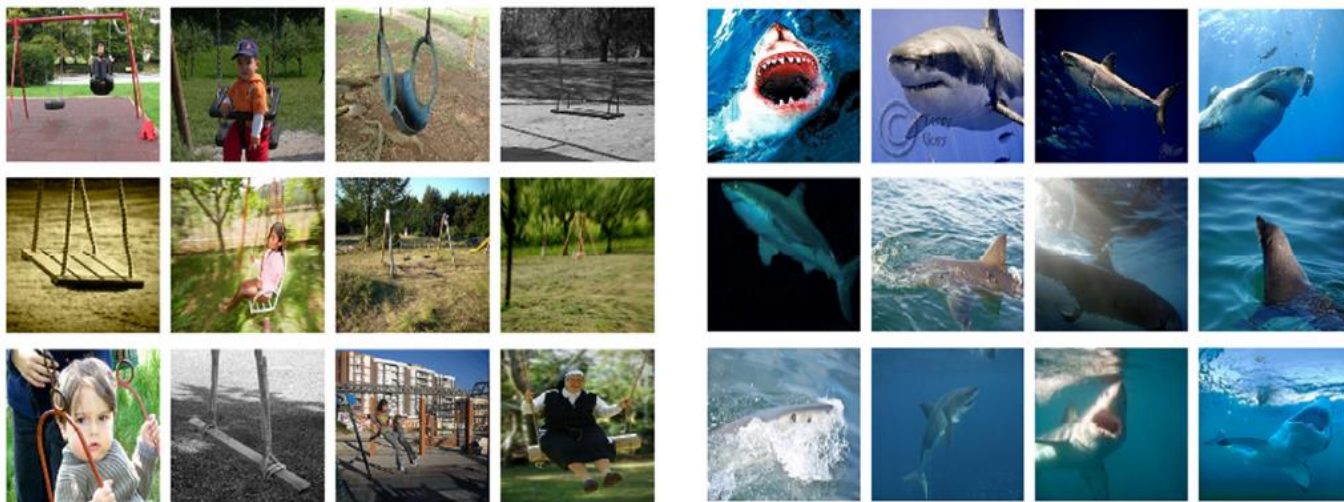
■ ImageNet 데이터베이스

- 2만 2천여 부류에 대해 부류별로 수백~수만장의 영상을 인터넷에서 수집하여 1500만여 장의 영상을 구축하고 공개

■ ILSVRC ImageNet Large Scale Visual Recognition Competition 대회 (CVPR 학술회에서 개최)

- 1000부류에 대해 분류, 검출, 위치 지정 문제: 1순위와 5순위 오류율로 대결
- 120만 장의 훈련집합, 5만 장의 검증집합, 15만 장의 테스트집합
- 우승: AlexNet (2012) → Clarifai팀 (2013) → GoogLeNet&VGGNet (2014) → ResNet(2015)

■ 우승한 CNN은 프로그램과 가중치를 공개함으로써 널리 사용되는 표준 신경망이 됨



(a) 'swing' 부류

(b) 'Great white shark' 부류


4.4 컨볼루션 신경망 사례연구

■ ILSVRC 영상 분류 예측 결과 예시



■ ILSVRC 성능 발전

ILSVRC'16 winner:
Error rate 2.991%

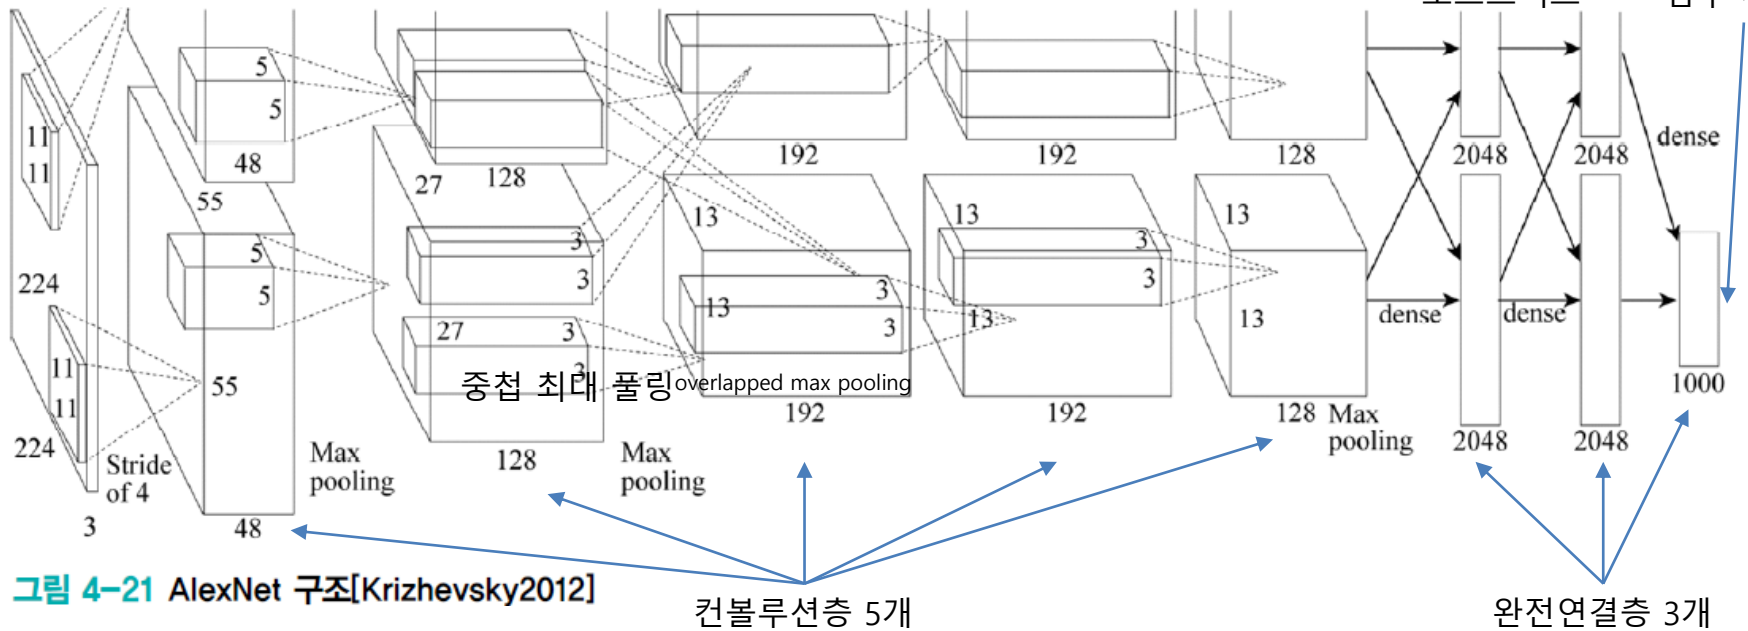


* Human-level performance: 5.1%

4.4.1 AlexNet

■ 구조

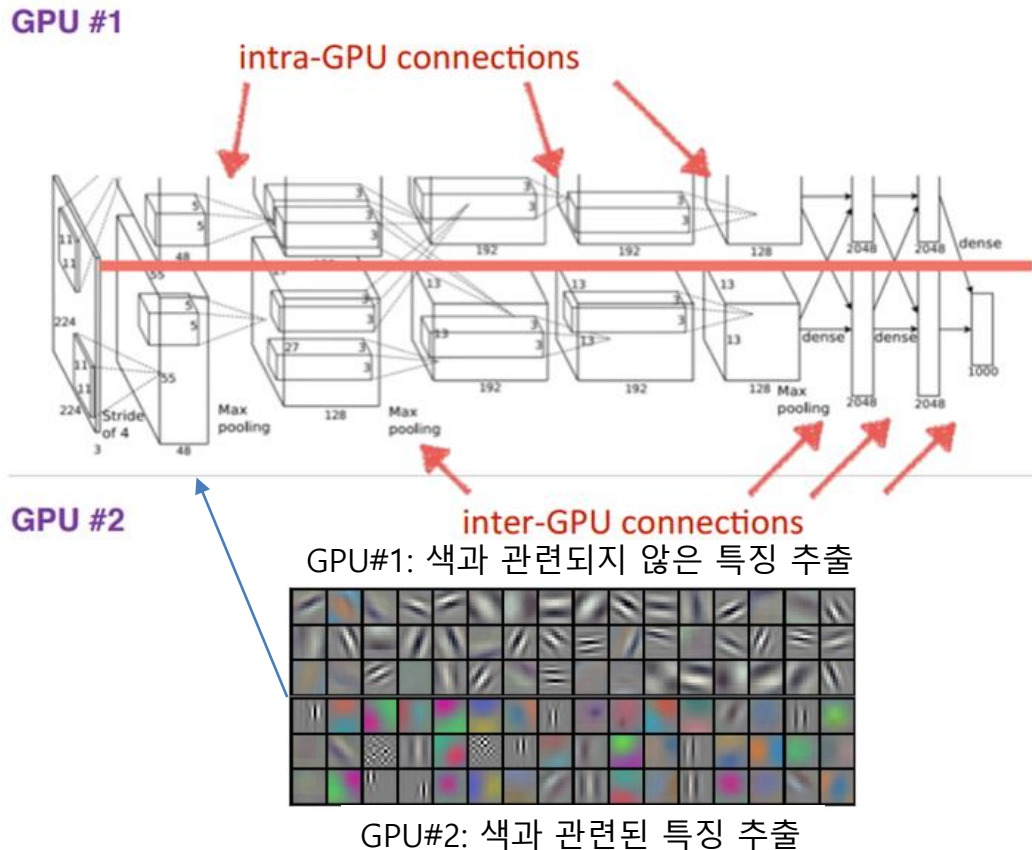
- **컨볼루션층 5개와 완전연결 fully connected (FC) 층 3개**
 - 8개 층에 290400-186624-64896-43264-4096-4096-1000개의 노드 배치
- 컨볼루션층은 200만개, FC층은 6500만개 가량의 매개변수
- FC층에 30배 많은 매개변수 → **향후 CNN은 FC층의 매개변수를 줄이는 방향으로 발전**
1000개의 분류를 위해 소프트맥스 softmax 함수 사용



4.4.1 AlexNet

■ 구조

- 당시 GPU의 메모리 크기 제한으로 인해 GPU#1, GPU#2으로 분할하여 학습 수행
- 1번째 컨볼루션 층 큰 보폭으로 다운샘플링 (풀링을 하지 않음)
- 3번째 컨볼루션 층은 GPU#1과 GPU#2의 결과를 함께 사용
- 마지막 층은 소프트맥스 함수를 적용하여 1000개의 분류




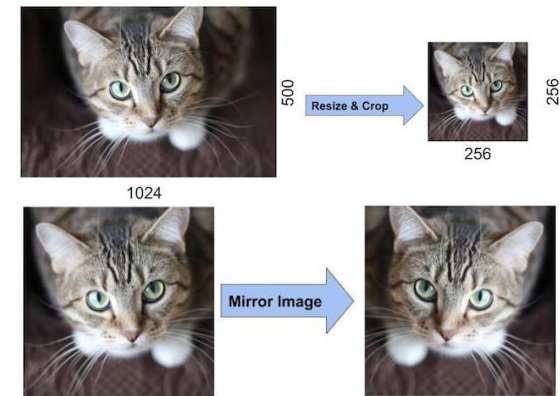

4.4.1 AlexNet

■ AlexNet이 학습에 성공한 요인

- 외적 요인
 - ImageNet이라는 대용량 데이터베이스
 - GPU를 사용한 병렬처리
- 내적 요인
 - 활성화함수로 ReLU 사용
 - 지역 반응 정규화(local response normalization) 기법 적용
 - 1번째, 3번째 최대 풀링 전 적용
 - 과잉적합 방지하는 여러 규제 기법 적용
 - 데이터 확대 (잘라내기cropping와 반전mirroring으로 2048배로 확대)
 - 드롭아웃dropout 등
 - » 완전연결층에서 사용됨

■ 테스트 단계에서 앙상블 적용

- [그림 5-26]과 [그림 12-5]
- 입력된 영상을 잘라내기와 반전을 통해 증가하고, 증가된 영상들의 예측 평균으로 최종 인식
- 2~3%만큼 오류율 감소 효과



4.4.2 VGGNet

■ VGGNet의 핵심 아이디어

- 3*3의 작은 커널을 사용
- 신경망을 더욱 깊게 만듦 (신경망의 깊이가 어떤 영향을 주는지 확인)
- 컨볼루션층 8~16개를 두어 AlexNet의 5개에 비해 2~3배 깊어짐

■ 16층짜리 VGG-16 (CONV 13층+FC 3층) [그림 4-22]

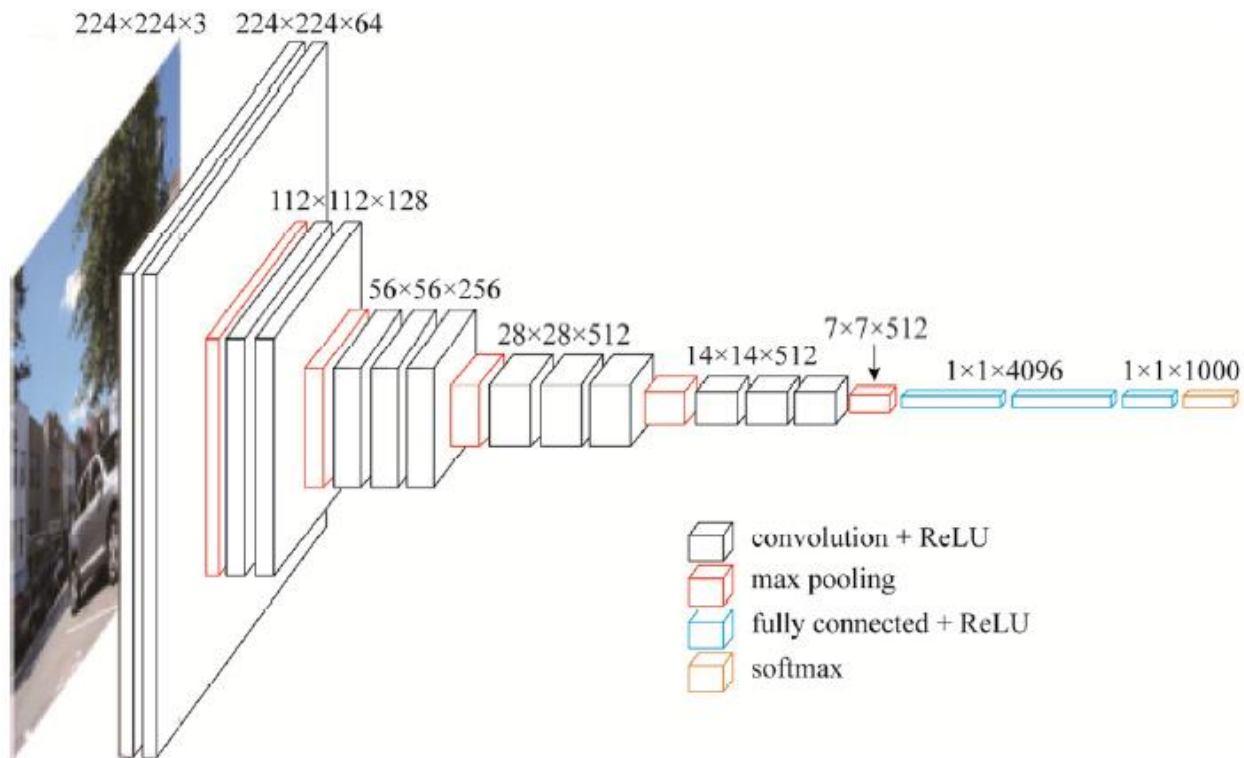


그림 4-22 VGGNet 구조[Simonyan2015]


4.4.2 VGGNet

■ 작은 커널의 이점 → GoogLeNet의 인셉션 모듈 영향

- 큰 크기의 커널은 여러 개의 작은 크기 커널로 분해될 수 있음

→ 매개변수의 수는 줄어들면서 신경망은 깊어지는 효과

- 예) 5×5 커널을 2층의 3×3 커널로 분해하여 구현




매개변수

5×5 커널인 경우, 25

3×3 커널인 경우, $9 + 9 = 18$

- 예) 3×3 커널을 1×3 커널과 3×1 커널로 분해하여 구현



매개변수

3×3 커널인 경우, 9

1×3 커널, 3×1 인 경우, $3 + 3 = 6$

→ 유사하게 $n \times n$ 커널은 $1 \times n$ 커널과 $n \times 1$ 커널로 분해될 수 있으며, n 이 클수록 매개변수의 수는 줄어드는 효과가 큼

4.4.2 VGGNet

■ 1*1 커널

■ 차원 축소 효과

- $c_2 > c_3$: 차원 축소 (연산량 감소), 깊은 신경망

■ [그림 4-23]의 예

- $m \times n$ 의 특징 맵 8개에 1×1 커널을 4개 적용 $\rightarrow m \times n$ 의 특징 맵 4개가 됨
- 다시 말하면, $8 \times m \times n$ 텐서에 $8 \times 1 \times 1$ 커널을 4개 적용하여 $4 \times m \times n$ 텐서를 출력하는 셈
- ReLU와 같은 비선형 활성화함수를 적용하면 특징 맵의 분별력 증가
- 『네트워크 속의 네트워크 network in network (NIN)』에서 유래 [Lin2014]
- VGGNet은 적용 실험을 하였지만 최종 선택하지는 않음 (GoogLeNet에서 사용됨)

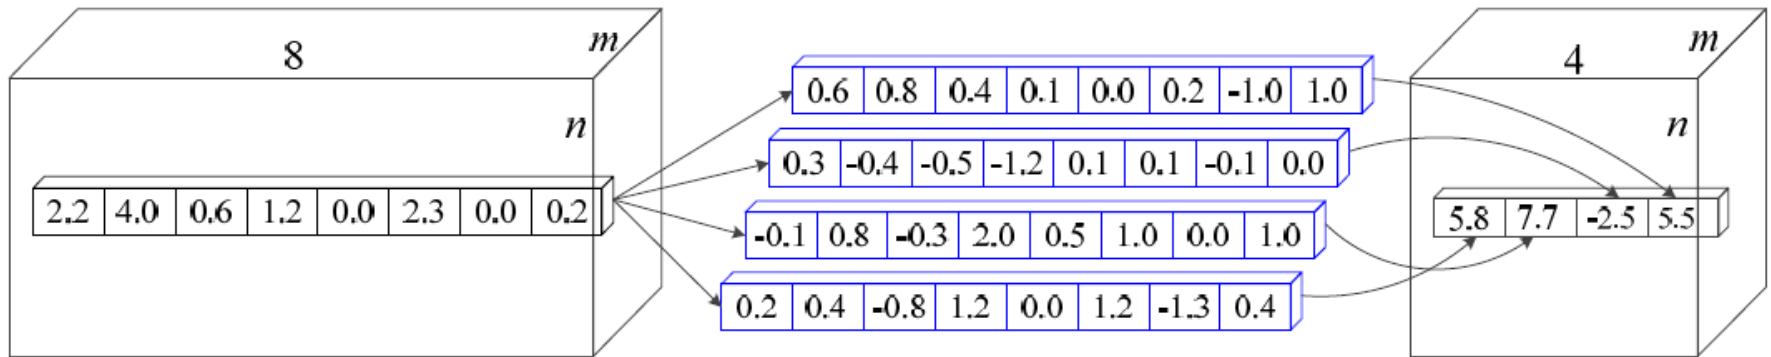
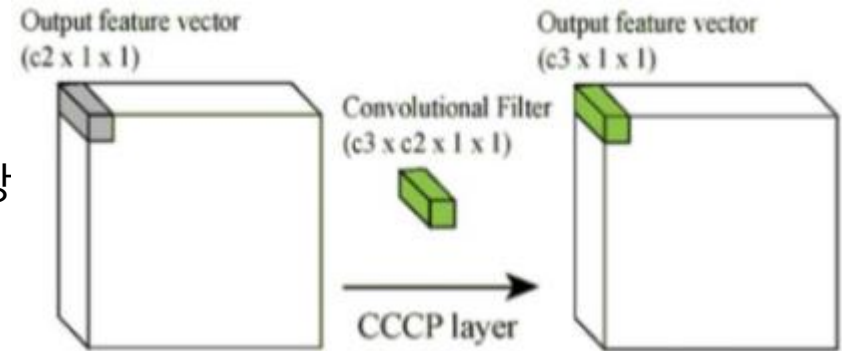



그림 4-23 1*1 컨볼루션 예제


4.4.3 GoogLeNet

■ GoogLeNet의 핵심 아이디어인 인셉션 모듈 inception module

- 수용장에서 더 다양한 특징을 추출하기 위해 NIN의 구조를 확장하여 여러 개의 병렬적인 컨볼루션 층을 가지도록 함
- NIN 구조
 - Mlpconv층이 컨볼루션 연산을 대신함 → 비선형 특성을 잘 표현하기 위함
 - Mlpconv는 커널을 옮겨가면서 MLP의 전방 계산을 수행함
 - MLP 또한 컨볼루션 연산처럼 오류 역전파를 통해 학습 가능



(a) 기존 컨볼루션층



(b) NIN의 Mlpconv층


그림 4-24 기존 컨볼루션 신경망과 NIN의 비교

Mlpconv층 (마이크로 네트워크)


4.4.3 GoogLeNet

■ NIN이 사용하는 전역 평균 풀링

- [그림 4-25(a)]의 VGGNet의 완전 연결층
 - 1억2천2백만 개의 매개변수를 가짐 (VGGNet의 전체 매개변수의 85%) → 과잉적합 원인
- [그림 4-25(b)]의 전역 평균 풀링 (global average pooling)
 - Mlpconv가 부류 수만큼 특징 맵을 생성하면, 특징 맵 각각을 평균하여 출력 노드에 입력 → 이 방식으로 매개변수를 줄임



(a) VGGNet의 완전연결



(b) NIN의 전역 평균 풀링

그림 4-25 완전연결과 NIN의 전역 평균 풀링의 비교

4.4.3 GoogLeNet

■ GoogLeNet은 NIN 개념을 확장한 신경망

■ 인셉션 모듈

- 마이크로 네트워크로 Mlpconv 대신 네 종류의 컨볼루션 연산 사용 → 다양한 특징 추출
- 1*1 컨볼루션을 사용하여 차원 축소 dimension reduction
 - 매개변수의 수 (=특징 맵의 수)를 줄임 + 깊은 신경망
- 3*3, 5*5 같은 다양한 크기의 컨볼루션들을 통해서 다양한 특징들을 추출

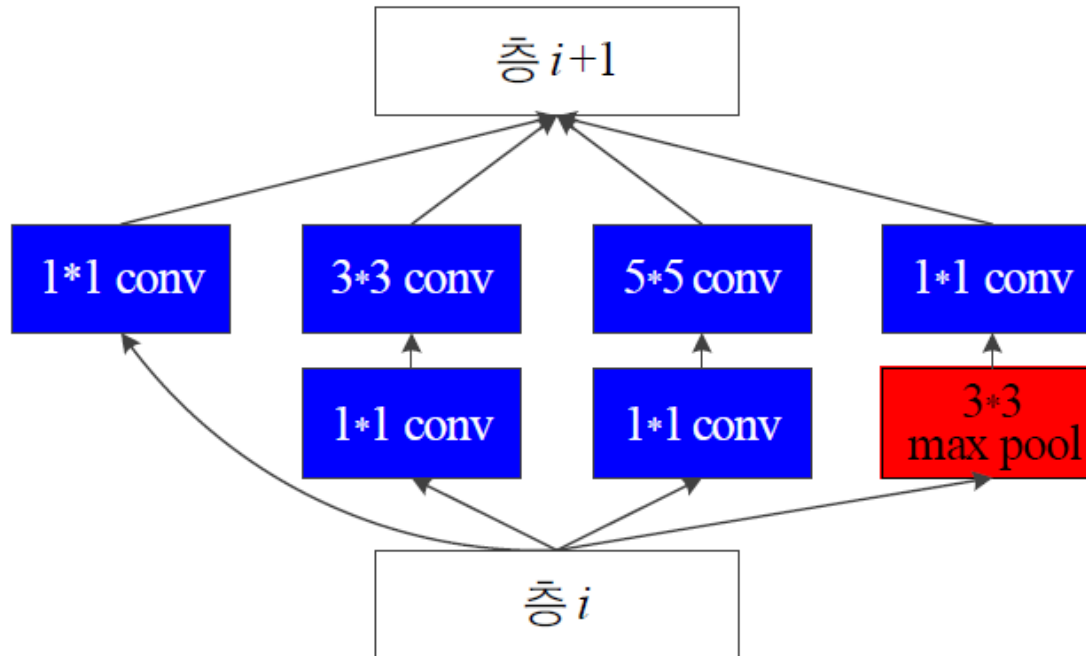


그림 4-26 GoogLeNet의 인셉션 모듈

4.4.3 GoogLeNet

■ 인셉션 모듈(I)을 9개 결합한 GoogLeNet ([그림 4-27])

- 매개변수가 있는 층 22개, 없는 층 (풀링) 5개로 총 27개 층
- 완전 연결층은 1개에 불과
 - 1백만 개의 매개변수를 가지며, VGGNet의 완전 연결층에 비하면 1%에 불과




그림 4-27 GoogLeNet의 구조

- 보조 분류기|auxiliary classifier
 - 원 분류기의 오류 역전파 결과와 보조 분류기의 오류 역전파 결과를 결합함으로써 **그레디언트 소멸 문제 완화**
 - 학습시에만 도우미 역할을 하고, 동작시에는 제거됨

4.4.4 ResNet

■ ResNet

- 잔류 학습(residual learning)이라는 개념을 이용하여 성능 저하를 피하면서 층 수를 대폭 늘림 (최대 1202층까지) ← 깊은 신경망일수록 데이터의 대표적인 특징을 잘 추출할 수 있음

- 원래 컨볼루션 신경망

$$\mathbf{F}(\mathbf{x}) = \tau(\mathbf{x} \circledast \mathbf{w}_1) \circledast \mathbf{w}_2$$
$$\mathbf{y} = \tau(\mathbf{F}(\mathbf{x}))$$

- 잔류 학습은 지름길 연결된 \mathbf{x} 를 더한 $\mathbf{F}(\mathbf{x}) + \mathbf{x}$ 에 τ 를 적용. $\mathbf{F}(\mathbf{x})$ 는 잔류(residual)

$$\mathbf{y} = \tau(\mathbf{F}(\mathbf{x}) + \mathbf{x})$$


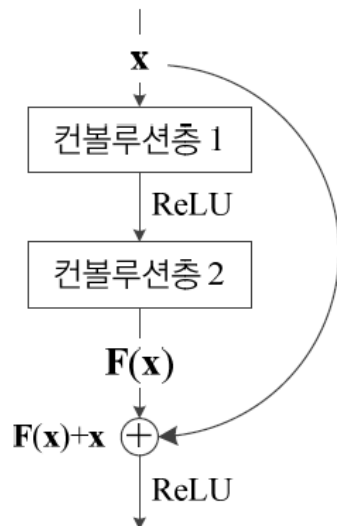


그림 4-28 잔류 학습의 구조와 동작

4.4.4 ResNet

■ 지름길 연결을 두는 이유는?

- 그레이디언트 소멸 문제 해결
- 식 (4.14)의 그레이디언트 식에서 $\frac{\partial}{\partial \mathbf{x}_l} \sum_{i=l}^{L-1} \mathbf{F}(\mathbf{x}_i)$ 이 -1이 될 가능성이 거의 없음

$$\frac{\partial \mathcal{E}}{\partial \mathbf{x}_l} = \frac{\partial \mathcal{E}}{\partial \mathbf{x}_L} \frac{\partial \mathbf{x}_L}{\partial \mathbf{x}_l} = \frac{\partial \mathcal{E}}{\partial \mathbf{x}_L} \left(1 + \frac{\partial}{\partial \mathbf{x}_l} \sum_{i=l}^{L-1} \mathbf{F}(\mathbf{x}_i) \right) \quad (4.14)$$

4.4.4 ResNet

■ 34층짜리 ResNet 예시




그림 4-29 ResNet 예제(34층)

■ VGGNet과 같은 점

- 3*3 커널 사용

■ VGGNet과 다른 점

- 잔류 학습 사용
- 전역 평균 풀링 사용 (FC 층 제거)
- 배치 정규화^{batch normalization} 적용 (드롭아웃 적용 불필요) → 배치 정규화는 5.2.6절

4.4.4 ResNet

■ ILSVRC 대회 성적

- 2012년 AlexNet의 15.3% 오류율은 당시로서 경이로운 성능
- 2015년에 ResNet은 3.5% 오류율 달성




그림 4-30 CNN의 발전 추세

4.4.4 ResNet

■ ILSVRC 대회

- 분류 문제는 성능 포화 (사람 성능에 필적함)
- 물체 검출 문제에 집중함




그림 4-31 ILSVRC 물체 검출 문제

4.5 생성 모델

- 4.5.1 생성 모델이란?
- 4.5.2 GAN

눈을 감고 황금 들녘을 상상해보라. 근사한 영상이 떠오른다면 머리 속에 있는 ‘생성 모델 generative model’이 작용한 탓이다. 사람의 생성 모델은 세상에 나타나는 현상을 오랫동안 지켜보면서 학습한 결과이다. 만일 기계 학습이 훈련집합을 사용하여 비슷한 생성 모델을 구축할 수 있다면 강한 인공지능^{strong AI}에 한발 다가설 수 있다. 왜냐하면 생성 모델은 분별 모델에 비해 데이터 생성 과정에 대한 보다 깊은 이해를 필요로 하기 때문이다[Karpathy2015].

4.5.1 생성 모델이란?

■ 분별 모델과 생성 모델의 비교

표 4-1 분별 모델과 생성 모델

모델	학습 단계가 할 일	예측 단계가 할 일	지도 여부
분별 모델	$P(y x)$ 추정	$f: x \mapsto y$	지도 학습
생성 모델	$P(x)$ 또는 $P(x y)$, $P(x, y)$ 추정	$f: \text{씨앗} \mapsto x$ 또는 $f: \text{씨앗 } y \mapsto x$, $f: \text{씨앗} \mapsto x, y$	비지도 학습

4.5.1 생성 모델이란?

예제 4-1

생성 모델과 분별 모델의 확률분포 추정과 예측

특징 벡터가 2차원이고 이진값을 가지며, 부류가 2개라 가정하자. 훈련집합은 다음과 같다.

$$\mathbb{X} = \left\{ \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \end{pmatrix}, \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \end{pmatrix}, \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \begin{pmatrix} 1 \\ 1 \end{pmatrix} \right\}, \mathbb{Y} = \{1, 1, 1, 0, 1, 0, 0, 0, 0, 1\}$$

생성 모델이 추정하는 확률 분포

$P(\mathbf{x}) =$

$\mathbf{x} = (0,0)^T$	0.2
$\mathbf{x} = (0,1)^T$	0.3
$\mathbf{x} = (1,0)^T$	0.1
$\mathbf{x} = (1,1)^T$	0.4

$P(\mathbf{x}|y) =$

	$y = 0$	$y = 1$
$\mathbf{x} = (0,0)^T$	0.0	0.4
$\mathbf{x} = (0,1)^T$	0.2	0.4
$\mathbf{x} = (1,0)^T$	0.2	0.0
$\mathbf{x} = (1,1)^T$	0.6	0.2

$P(\mathbf{x}, y) =$

	$y = 0$	$y = 1$
$\mathbf{x} = (0,0)^T$	0.0	0.2
$\mathbf{x} = (0,1)^T$	0.1	0.2
$\mathbf{x} = (1,0)^T$	0.1	0.0
$\mathbf{x} = (1,1)^T$	0.3	0.1



4.5.1 생성 모델이란?

분별 모델이 추정하는 확률 분포

$$P(y|\mathbf{x}) =$$

	$y = 0$	$y = 1$
$\mathbf{x} = (0,0)^T$	0.0	1.0
$\mathbf{x} = (0,1)^T$	0.33	0.67
$\mathbf{x} = (1,0)^T$	1.0	0.0
$\mathbf{x} = (1,1)^T$	0.75	0.25

학습을 마쳤으니, 이제 예측 단계를 수행해보자. 생성 모델이 $P(\mathbf{x})$ 를 사용하고, 네 가지 \mathbf{x} 값의 확률에 따라 $\begin{pmatrix} 0 \\ 0 \end{pmatrix}$ 에게 $[0.0, 0.2]$, $\begin{pmatrix} 0 \\ 1 \end{pmatrix}$ 에게 $(0.2, 0.5]$, $\begin{pmatrix} 1 \\ 0 \end{pmatrix}$ 에게 $(0.5, 0.6]$, $\begin{pmatrix} 1 \\ 1 \end{pmatrix}$ 에게 $(0.6, 1.0]$ 구간을 부여하자. 난수로 0.34가 나오면 $(0.2, 0.5]$ 에 속하므로 $\begin{pmatrix} 0 \\ 1 \end{pmatrix}$ 을 생성하고, 0.83이 나오면 $(0.6, 1.0]$ 에 속하므로 $\begin{pmatrix} 1 \\ 1 \end{pmatrix}$ 을 생성한다.

분별 모델의 예측을 생각해보자. 만일 테스트 샘플 $\begin{pmatrix} 0 \\ 1 \end{pmatrix}$ 이 주어지면, $P\left(y = 0 | \mathbf{x} = \begin{pmatrix} 0 \\ 1 \end{pmatrix}\right) = 0.33$ 이고 $P\left(y = 1 | \mathbf{x} = \begin{pmatrix} 0 \\ 1 \end{pmatrix}\right) = 0.67$ 이므로 $y = 1$ 이라고 분류하면 된다.

4.5.1 생성 모델이란?

■ 실제 상황에서 생성 모델

- 현실에 내재한 데이터 발생 분포 $P_{data}(\mathbf{x}) \rightarrow$ 알아낼 수 없음




그림 4-32 확률분포 $P_{data}(\mathbf{x})$ 에 따른 자연 영상의 발생 과정

- $P_{data}(\mathbf{x})$ 를 모방하는 모델의 확률 분포 $P_{model}(\mathbf{x}; \theta)$
 - $P_{model}(\mathbf{x}; \theta)$ 를 명시적으로 추정하는 것도 불가능
 - 현대 기계 학습은 주로 딥러닝 모델을 사용하여 확률 분포를 암시적으로 표현
 - GAN (generative adversarial network), VAE (variational autoencoder), RBM (10장)

4.5.2 GAN(generative adversarial network)

■ GAN의 우월한 성능

- 사람을 상대로 진짜와 가짜 구별하는 실험에서
MNIST 52.4%, CIFAR-10 78.7% (50%이면 완벽히 속임)




그림 4-33 GAN으로 생성한 영상 샘플

4.5.2 GAN

■ GAN의 아이디어

- 생성기(generator G)와 분별기(discriminator D)의 대립 구도

- G는 가짜 샘플 생성 (위조지폐범)
- D는 가짜와 진짜를 구별 (경찰)

- GAN의 목표는 위조지폐범의 승리

(G가 만들어내는 샘플을 D가 구별하지 못하는 수준까지 학습)

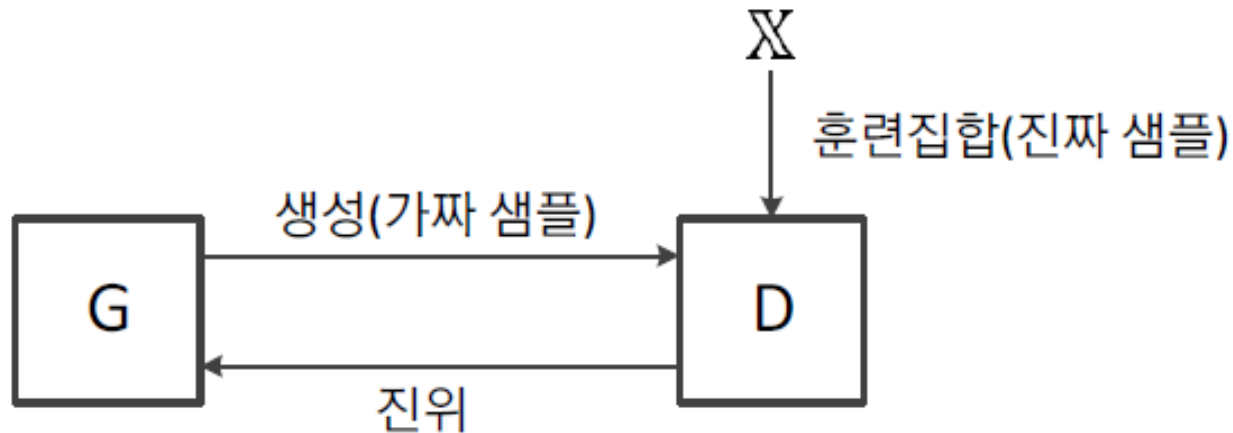


그림 4-34 GAN의 원리

4.5.2 GAN

- 향후, 자세히 다룰 예정

4.6 딥러닝은 왜 강력한가?

■ 종단간^{end-to-end} 최적화된 학습 가능

- 고전적인 방법에서는
 - [그림 4-37]처럼 분할, 특징 추출, 분류를 따로 구현한 다음 이어 붙임
 - 사람의 직관에 따르므로 성능 한계
 - 인식 대상이 달라지면 새로 설계해야 함




그림 4-37 여러 단계를 따로 설계 구현하는 고전적인 접근방식(나뭇잎 인식 사례)

- 딥러닝은 전체 과정을 동시에 최적화 (통째 학습이라 부름)




그림 4-2 깊은 신경망의 처리 절차

4.6 딥러닝은 왜 강력한가?

■ 깊이^{depth}의 중요성

- 점선은 20개 노드를 가진 은닉층 하나 짜리 신경망
- 실선은 각각 10개 노드를 가진 은닉층 두 개 짜리 신경망 → 더 정교한 분할




그림 4-38 은닉층의 개수가 늘어남에 따른 표현력 증가

4.6 딥러닝은 왜 강력한가?

■ 계층적 특징 hierarchical features

- [그림 4-40]은 ImageNet으로 학습한 특징 맵 → 계층 구조
 - 깊은 신경망에서는 층의 역할이 잘 구분됨
- 반면 얇은 신경망은 하나 또는 두 개의 은닉층이 여러 형태의 특징을 모두 담당

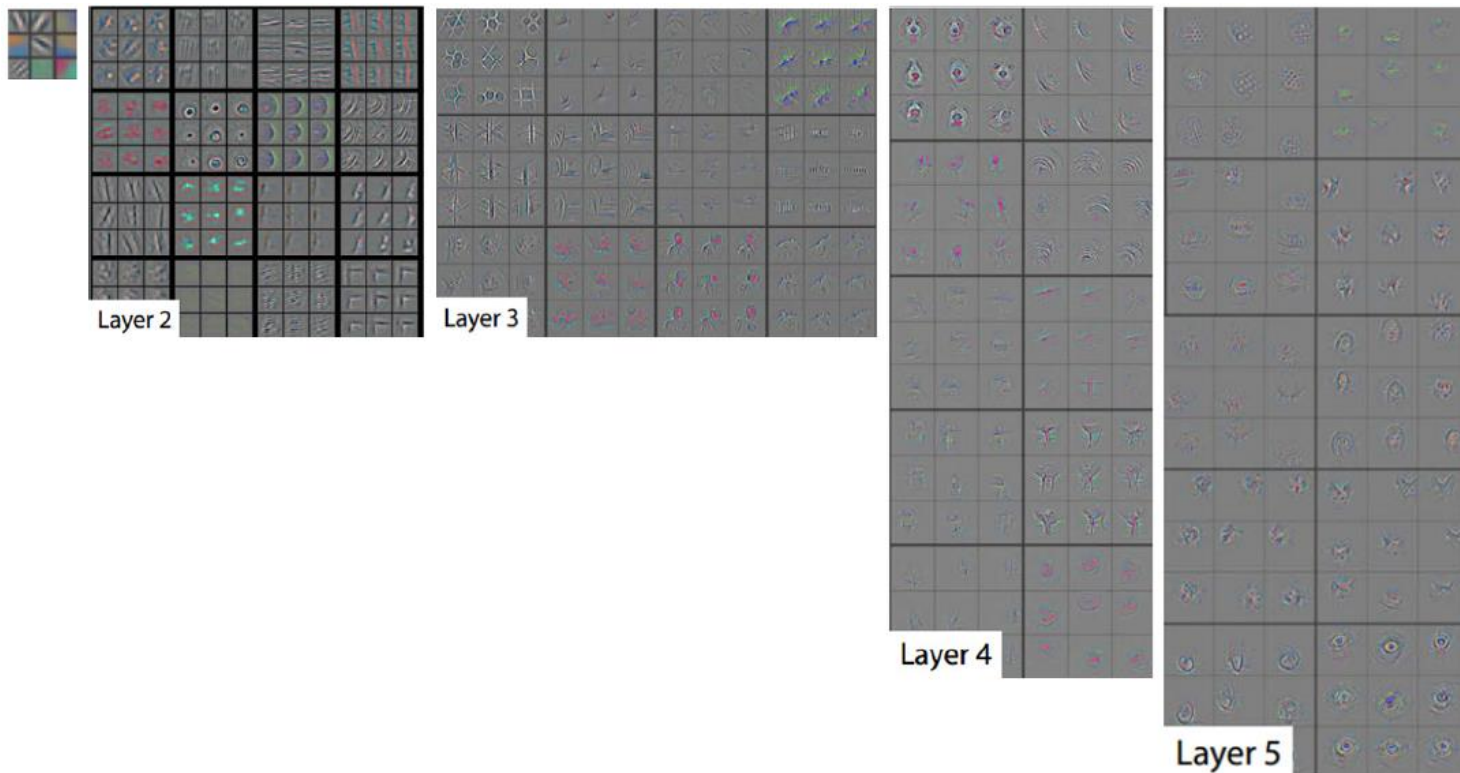


그림 4-40 CNN의 계층적 특징 추출